

**«Санкт-Петербургский государственный электротехнический университет
«ЛЭТИ» им. В.И. Ульянова (Ленина)»
(СПбГЭТУ «ЛЭТИ»)**

Направление	09.04.02 – Информационные системы и технологии
Профиль	Распределенные вычислительные комплексы систем реального времени
Факультет	ФКТИ
Кафедра	ИС

К защите допустить

Зав. кафедрой

подпись

Цехановский В.В.

**ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
МАГИСТРА**

**Тема: Методика анализа политик безопасности на основе
онтологического представления предметной области**

Студент

подпись

Кузнецов М.Д.

Руководитель

к.т.н., доцент
(Уч. степень, уч. звание)

подпись

Новикова Е.С.

Консультант

к.э.н., доцент
(Уч. степень, уч. звание)

подпись

Жукова Т.Н.

Санкт-Петербург

2021

ЗАДАНИЕ НА ВЫПУСКНУЮ КВАЛИФИКАЦИОННУЮ РАБОТУ

Утверждаю
Зав. кафедрой ИС
_____ Цехановский В.В.
подпись
« ____ » _____ 2021 г.

Студент Кузнецов М.Д.

Группа 5374

Тема работы: Методика анализа политик безопасности на основе онтологического представления предметной области.

Место выполнения ВКР: Санкт-Петербургский государственный электротехнический университет «ЛЭТИ» им. В.И.Ульянова (Ленина)

Исходные данные (технические требования): —

Содержание ВКР: в разделе «Анализ предметной области» произведен анализ литературы и работ в данной области, в разделе «Проектирование инструментария» проведено проектирование инструментария, в разделе «Результаты реализации инструментария» приведены результаты ВКР магистра.

Перечень отчетных материалов: пояснительная записка, иллюстрационный материал.

Дополнительные разделы: «Составление бизнес-плана по коммерциализации результатов научно-исследовательской работы магистра».

Дата выдачи задания

« ____ » _____ 2021 г.

Дата представления ВКР к защите

« ____ » _____ 2021 г.

Студент

подпись

Кузнецов М.Д.

Руководитель

к.т.н., доцент
(Уч. степень, уч. звание)

подпись

Новикова Е.С.

Консультант

к.э.н., доцент
(Уч. степень, уч. звание)

подпись

Жукова Т.Н.

КАЛЕНДАРНЫЙ ПЛАН ВЫПОЛНЕНИЯ ВЫПУСКНОЙ КВАЛИФИКАЦИОННОЙ РАБОТЫ

Утверждаю
Зав. кафедрой ИС
Цехановский В.В.
_____ *подпись*
« _____ » _____ 2021 г.

Студент Кузнецов М.Д.

Группа 5374

Тема работы: Методика анализа политик безопасности на основе онтологического представления предметной области.

№ п\п	Наименование работ	Срок выполнения
1	Обзор литературы по теме работы	01.02 – 28.02
2	Анализ предметной области	01.03 – 31.03
3	Проектирование инструментария разметки	01.04 – 15.04
4	Реализация инструментария разметки	15.04 – 30.04
5	Составление плана по коммерциализации НИР магистра	01.05 – 07.05
6	Оформление пояснительной записки	07.05 – 10.05
7	Оформление иллюстративного материала	10.05 – 15.05

Студент

_____ *подпись*

Кузнецов М.Д.

Руководитель

к.т.н., доцент
(Уч. степень, уч. звание)

_____ *подпись*

Новикова Е.С.

Консультант

к.э.н., доцент
(Уч. степень, уч. звание)

_____ *подпись*

Жукова Т.Н.

РЕФЕРАТ

Поясн. зап. 119 стр., 41 рис., 32 табл., 25 ист., 3 прил.

АВТОМАТИЗИРОВАННАЯ ОБРАБОТКА ЕСТЕСТВЕННОГО ЯЗЫКА, ПОЛИТИКИ БЕЗОПАСНОСТИ, ПОЛЬЗОВАТЕЛЬСКИЕ СОГЛАШЕНИЯ, ОНТОЛОГИЧЕСКОЕ ПРЕДСТАВЛЕНИЕ

Объектом исследования являются способы эффективной автоматизированной формализации политик безопасности.

Цель работы – разработать эффективный план и автоматизированные способы формализации политик безопасности на основе онтологического представления предметной области, разработать инструменты создания обучающей выборки для автоматизированной формализации политик безопасности, что является промежуточным шагом для автоматизированной оценки угроз персональным данным.

Политики конфиденциальности предоставляют пользователям информацию о том, как их личные данные собираются, обрабатываются и передаются третьим лицам. В большинстве случаев они написаны нечетко и непрозрачно, поэтому важно сделать политику конфиденциальности ясной и прозрачной для конечного пользователя. Было исследовано применение методов LSA и LDA для обнаружения семантических особенностей, представленных в политиках конфиденциальности. Также тестируется POS подход с пулами синонимов. Однако, такие строгие методы обработки текста не очень точны. Использование методов глубокого обучения с онтологическим представлением предметной области делает возможной точную формализацию политик конфиденциальности. Для этого были созданы веб-скрейпер и инструмент аннотирования. С помощью веб-скрейпер был получен набор данных из 592 политик конфиденциальности. Программный комплекс – шаг к автоматизированной оценке угроз персональным данным.

ABSTRACT

Privacy policies provide end users information about how they personal data are collected, processed and shared with third parties. However, in major cases they are written in unclear and not transparent manner. So, it is important to make privacy policies clear and transparent to end user. In this work, application of the LSA and LDA techniques to detect semantic features presented in the privacy policy are investigated. Also POS with synonyms pools is tested. However, more strict ways of text processing are not very accurate. Using deep learning techniques with ontology representation of subject domain making accurate privacy policy formalization possible. For that the crawler and annotation tool were created. Finally, the privacy policies dataset consisting of 592 was obtained with the crawler. Also the annotation methodic was proposed with corresponding annotation tool. Program package – step to automated privacy policies threats detections and risk analysis.

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ

В настоящей пояснительной записке к выпускной квалификационной работе используются следующие термины с соответствующими определениями.

Датасет — набор данных для обучения моделей анализа естественного языка

Вэб-скрейпинг — это технология извлечения данных из вэб-страниц путем из скачивания и обработки

Формализация — представление какой-либо содержательной области в виде формальной системы или исчисления.

Политика безопасности — совокупность документированных руководящих принципов, правил, процедур и практических приёмов в области безопасности, которые регулируют управление, защиту и распределение ценной информации.

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ

В настоящей пояснительной записке к выпускной квалификационной работе используются следующие сокращения и обозначения.

E-P3P — (от англ. Platform for Privacy Preferences Project) протокол, позволяющий веб-сайтам заявлять о предполагаемом использовании собираемой информации о пользователях веб-браузера

GPS — (от англ. Global Positioning System) система глобального позиционирования

HR — (от англ. Human Resource) кадровая служба

IoT — (от англ. Internet of Things) интернет вещей

IT — (от англ. Information Technologies) информационные технологии

LDA — (от англ. Latent Dirichlet Allocation) латентное размещение Дирихле

LSA — (от англ. Latent Semantic Search) латентно-семантический анализ

ML — (от англ. Machine Learning) машинное обучение

NLP — (от англ. Natural Language Processing) обработка естественного языка

NPV — (от англ. Net Present Value) чистая текущая стоимость проекта

PII — (от англ. Personally Identifiable Information) информация об идентифицируемом субъекте

POS — (от англ. Part Of Speech) разложение по частям речи

SVC — (от англ. Support Vector Machine) метод опорных векторов

TF-IDF — (от англ. Term Frequency – Inverse Document Frequency) инверсная частотная характеристика документа

UML — (от англ. Unified Modeling Language) унифицированный язык моделирования

WACC — (от англ. Weight average cost of capital) средневзвешенная стоимость капитала

Wi-Fi — (от англ. Wireless Fidelity) технология беспроводной локальной сети с устройствами на основе стандартов IEEE 802.11.

СУБД — система управления базами данных

СОДЕРЖАНИЕ

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ	4
ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ	5
ВВЕДЕНИЕ	11
1 Анализ предметной области	14
1.1 Сравнительный анализ актуальных работ	14
1.2 Онтологическое представление политик безопасности	22
1.3 Алгоритм оценки рисков на основе онтологического представления	30
1.4 Постановка задачи	32
2 Проектирование инструментария	33
2.1 Применение строгих методов анализа текста для формализации политик безопасности	33
2.1.1 Статистические модели текстовых документов	33
2.1.2 Подход основанный на латентно-семантическом анализе текста	34
2.1.3 Подход основанный на латентном размещении Дирихле	39
2.1.4 Подход основанный на применении контекстно-свободных грамматик и синонимическом поиске	44
2.1.5 Выводы по строгим методам текстового анализа	49
2.2 Техническое задание «Инструментарий для сбора датасета»	50
2.2.1 Скрейпер веб-страниц	50
2.2.2 Очистка скачанных страниц политик	50
2.2.3 Инструмент разметки датасета	51
2.2.4 Фреймворки глубокого обучения	51
2.3 Методика сбора	51
2.4 Методика очистки	53
2.5 Методика разметки	54
2.6 Потенциальные проблемы	56

2.7 Приложение веб-скрейпер	58
2.7.1 Первичная декомпозиция и планирование	58
2.7.2 Структура приложения веб-скрейпера	58
2.7.3 Средства разработки веб-скрейпера	64
2.8 Инструмент разметки датасета	65
2.8.1 Объектное моделирование приложения	66
2.8.2 Реляционная модель приложения	67
2.8.3 Проектирование пользовательского интерфейса	68
2.8.4 Диаграммы классов инструмента разметки	72
2.8.5 Средства разработки инструмента разметки	74
2.9 Результаты этапа проектирования инструментария	75
3 Результаты реализации инструментария	76
3.1 Полученные в результате реализации исходные коды	76
3.2 Полученный в результате сбора данных датасет	76
3.3 Полученный в результате реализации инструмент разметки	84
3.4 Итоги этапа реализации	88
4 Составление бизнес-плана по коммерциализации результатов научно-исследовательской работы магистра	89
4.1 Описание концепции проекта	89
4.1.1 Название проекта	89
4.1.2 Сущность проекта	89
4.1.3 Реальная бизнес-ситуация, служащая обоснованием проекта ...	89
4.1.4 Цели проекта	90
4.1.5 Границы проекта	90
4.1.6 Допущения	90
4.1.7 Заинтересованные стороны проекта	91
4.1.8 Риски проекта	91
4.1.9 Ориентировочные сроки проекта	91

4.1.10 Первоначальная организация проекта	91
4.1.11 Ориентировочный бюджет проекта	92
4.2 Описание продукции	92
4.3 Анализ рынка сбыта продукции	93
4.3.1 Положение дел в отрасли.....	93
4.3.2 Характеристика внешней среды проекта	93
4.3.3 Анализ рынка	95
4.3.4 Сегментирование рынка и выбор целевых сегментов.....	96
4.4 Анализ конкурентов	96
4.5 План маркетинга	97
4.5.1 Товарная политика	97
4.5.2 Распределительная политика	98
4.5.3 Коммуникационная политика.....	98
4.5.4 Ценовая политика.....	100
4.5.5 План продаж	101
4.6 План производства	103
4.6.1 Производственная база.....	103
4.6.2 Потребность в производственном персонале	104
4.6.3 Расчет общепроизводственных затрат	104
4.6.4 Расчет общехозяйственных, управленческих и коммерческих расходов	105
4.6.5 Расчет инвестиционных расходов	105
4.6.6 Расчет затрат на разработку продукта	106
4.7 Организационный план	106
4.7.1 Характеристика организации, реализующей проект	106
4.7.2 Нормативно-правовое регулирование	106
4.7.3 Организационная структура	106
4.7.4 Календарный план проекта.....	107

4.8 Финансовый план	107
4.8.1 План прибылей и убытков	108
4.8.2 Показатели эффективности инвестиций	109
4.9 Оценка риска проекта	110
4.10 Результаты составления бизнес-плана по коммерциализации результатов научно-исследовательской работы магистра	111
ЗАКЛЮЧЕНИЕ	112
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	114
ПРИЛОЖЕНИЕ А	117
ПРИЛОЖЕНИЕ Б	118
ПРИЛОЖЕНИЕ В	119

ВВЕДЕНИЕ

В настоящее время персональные данные широко используются в предоставлении цифровых услуг, их персонализации и улучшении. Персональные данные – это любые данные, позволяющие идентифицировать физическое лицо [1]. Таким образом, личные данные – это не только биометрическая информация, данные о состоянии здоровья человека, а также фото абонента услуги, местонахождение, информация о приложении и устройстве, которое можно использовать для отслеживания действий и информации о потребителе. Несколько массовых утечек персональных данных за последнее десятилетие привело к ужесточению законодательных требований во многих странах по всему миру. В настоящее время требуется, чтобы все личные данные обрабатывались надежно в соответствии явно указанным согласием субъекта данных, а действия с ними были ясны и прозрачны. Политики конфиденциальности поставщиков услуг, онлайн-согласия пользователей – единственные законные документы, сообщающие конечным пользователям, как их личные данные собираются, обрабатываются и передаются третьим лицам. Однако в большинстве случаев эти документы написаны так, что их довольно сложно понять. И в настоящее время ситуация такова, что законодательные требования соблюдаются производителями продукции и поставщиками услуг, но конечные пользователи дают свое согласие без четкого понимания того, как обрабатываются их личные данные, потому что политика конфиденциальности или онлайн-согласие пользователя читаются редко из-за их сложности и низкой читабельности. Это ведет к ситуациям, когда конечные пользователи не знают о рисках для их конфиденциальности, связанных с использованием определенной услуги или устройства.

На момент написания выпускной квалификационной работы актуальность данной работы является высокой, так как формализация политик безопасности открывает возможности для более простой и ясной формулиров-

ки, что уменьшит количество угроз персональным данным. Также становится возможной разработка методик расчета рисков потребления цифровых услуг и устройств, подпадающих под соответствующие политики конфиденциальности.

Цель работы – разработать эффективный план автоматизированного решения по формализации политик безопасности на основе онтологического представления, разработать инструменты создания обучающей выборки для автоматизированной формализации политик безопасности.

В ходе выполнения предполагается реализация инструментов для сбора датасета, который будет применен для обучения классификатора. Классификатор позволит автоматизированно формализовать политики безопасности. По формализованному описанию политик станет возможной оценка рисков для персональных данных пользователей.

Для достижения данной цели необходимо:

- провести анализ предметной области;
- разработать методики сбора, очистки и разметки обучающей выборки;
- спроектировать инструментарий для построения обучающей выборки, обеспечивающей обучение классификатора с учетом онтологического представления предметной области;
- реализовать инструментарий для построения обучающей выборки, обеспечивающей обучение классификатора с учетом онтологического представления предметной области.

Выпускная квалификационная работа состоит из введения, трех разделов и заключения. В первом разделе производится анализ предметной области. Во втором разделе проведены эксперименты со строгими методами текстового анализа и обоснование необходимости использования моделей текстового анализа, основанных на глубоком обучении. В том же разделе описаны приемы и методики, произведено проектирование инструментария. В

третьем разделе описаны результаты разработки. В четвертом разделе предложен план по коммерциализации научно-исследовательской работы магистра.

1 Анализ предметной области

Работы по проблеме, решаемой в выпускной квалификационной работе, можно разделить на три группы. Первая группа – работы, связанные с анализом рисков конфиденциальности. Вторая группа работ связана с анализом политик, представленных на естественном языке, и их дальнейшим представлением в удобной форме. Для этого используются методы обработки естественного языка (NLP). Третья группа работ посвящена разработке единого стандарта политик конфиденциальности и их автоматизированной генерации. Для этого используются методы разработки формальных языков.

Эти три группы взаимосвязаны с точки зрения формализации политик безопасности. Сначала тексты политики конфиденциальности, представленные на естественном языке, обрабатываются для формального определения политик конфиденциальности (с использованием некоторого формального языка), наконец, политики конфиденциальности, указанные на формальном языке, могут быть применены для расчета рисков конфиденциальности.

1.1 Сравнительный анализ актуальных работ

Анализ текстов политик конфиденциальности, представленных на естественном языке, рассматривается в статьях [2], [3], [4].

В работе [2] описан подход к автоматизированному извлечению и анализу политик конфиденциальности для приложений Android. Авторы используют подход TF-IDF для построения вектора признаков текста политик и классификатор на основе машины опорных векторов для обнаружения различных методов обработки данных, таких как контактный адрес электронной почты, контактный номер телефона, местоположение GPS или Wi-Fi и т.д. Для обучения моделей авторы создали аннотированный корпус политик конфиденциальности APP-350.

В статье [3] описана семантическая структура PrivOnto для анализа политик конфиденциальности. PrivOnto использует в качестве входных данных

набор аннотированных политик конфиденциальности и разработанную общую онтологию. Предлагаемая онтология представляет собой набор политик с определенными практиками в отношении данных с учетом их конфиденциальности. Эксперты проанализировали набор политик конфиденциальности и вручную аннотировали их, используя 11 выделенных категорий методов обработки данных: «First-party Collection/Use», «Third-party Sharing/Collection», «User Choice/Control», «User Access/Edition/Deletion», «Data Retention», «Data Security», «Policy Change», «Do Not Track», «International and Special Audience» и другие. Исследователи аннотировали более 23000 практик обработки данных, извлеченных из 115 политик конфиденциальности. Затем аннотированный набор использовался для обучения классификатора для автоматизированного аннотирования. Авторы использовали краудсорсинг, машинное обучение и обработку естественного языка для автоматизированного аннотирования политик конфиденциальности и создания онтологий. Это исследование предлагает один из самых эффективных подходов, однако авторы данной работы не уделяют внимания оценке рисков.

Онтологический подход к представлению политики конфиденциальности также предлагается в статьях [5], [6]. В работе [5] авторы разработали онтологию конфиденциальности PrOnto для проверки соответствия политики GDPR, однако они генерируют онтологию вручную. В работе [6] предлагается подход, основанный на построении онтологии с использованием вопросов компетенции.

В работе [4] описывается подход к автоматическому обнаружению вариантов отказа от некоторых способов сбора и использования личных данных в текстах политик конфиденциальности на основе машинного обучения. Авторы [4] протестировали различные методы машинного обучения для анализа текста политик, такие как линейная регрессия и нейронные сети. Ограничение подхода состоит в том, что для его применения требуется размеченный набор данных. Авторы реализовали разметку вручную. В статье [7] так-

же рассматривается автоматическое обнаружение вариантов отказа в текстах политик конфиденциальности. Авторы используют набор данных из статьи [3] для обучения своих моделей.

Разработка формальных языков для автоматизированной генерации и единой спецификации политик конфиденциальности рассматривается в статьях [8]–[12]. Формальный язык состоит из языкового алфавита и правил построения последовательностей с использованием символов алфавита, то есть языковой грамматики. Текст, указанный на таком языке, можно обработать математическими методами.

В статье [8] предлагается платформа для корпоративных практик конфиденциальности E-P3P, чтобы формализовать политику конфиденциальности на машиночитаемом языке. Этот язык может быть применен на предприятии. Формализованная политика определяет, какие типы личной информации РИ, для каких целей и какими пользователями в организации могут быть использованы. Машиночитаемый язык включает терминологию и набор правил авторизации. Терминология включает категории данных, цели, пользователей данных, набор действий, набор обязательств и набор условий. Правила авторизации используются, чтобы разрешить или запретить действие. Аналогичный подход к управлению авторизацией и контролю доступа представлен в работе [9]. Предлагаемая модель состоит из пользователей/групп, используемых данных, целей доступа и режимов доступа. Он используется для обеспечения того, чтобы личная информация использовалась только для авторизации. Авторы [9] также предложили язык конфиденциальности, основанный на упомянутой модели. Этот язык используется для формализации правил конфиденциальности, контроля доступа и автоматического применения этих правил с помощью системы контроля доступа. Предлагаемая модель ограничивается только контролем доступа с учетом аспектов конфиденциальности.

В публикации [10] так же используется подход, основанный на языко-

вых методах. Авторы [10] рассматривают принцип конфиденциальности, который гласит, что личные данные пользователя не могут использоваться для целей, отличных от той, для которой они были собраны, без согласия субъекта данных. Авторы [10] предполагают, что в большинстве случаев пользователи не имеют представления о том, как и для каких целей используется их личная информация. Чтобы решить эту проблему, авторы предлагают политику обработки данных DHP [10], показывающую пользователям, кто и на каких условиях может обрабатывать их личные данные. Эта политика может быть разработана поставщиком услуг или пользователем с использованием языка DHP. Язык включает набор условий и правил, а именно: получателей, действия, цели, РП, условия, положения и обязательства. Затем DHP применяется в точках принятия решения по политике (принятие решения в отношении запроса доступа) и точек реализации политики (реализация решения) системы управления доступом. Минус в том, что такую политику нужно разрабатывать для каждого нового продукта.

В статье [11] предлагается язык PILOT для спецификации политики конфиденциальности. Авторы также разработали инструмент, позволяющий оценивать риски, связанные с конфиденциальностью, если политика определяется с использованием предложенного языка. Преимущество подхода в том, что он позволяет оценивать риски. Недостатком является то, что такой подход не позволяет оценивать их автоматически, если политика не задана на разработанном формальном языке. Авторы предлагают пользователям самим определять политики конфиденциальности, а затем представляют оценку рисков политики.

В работе [12] предлагается многоуровневый язык конфиденциальности LPL [12], который удовлетворяет следующим требованиям: различие между источником и получателем данных, создание политик конфиденциальности с учетом целей, операций с данными, гарантия удобочитаемости на основе многоуровневых политик конфиденциальности. К недостаткам этой работы

можно отнести: исследование не завершено, и предлагаемая формулировка сейчас не охватывает все аспекты конфиденциальности; компания должна определить свою политику конфиденциальности, используя LPL, прежде чем анализировать ее. Оценка рисков конфиденциальности, заданная с использованием формального языка PILOT, рассматривается в [11].

Отдельно следует отметить подходы, позволяющие рассчитывать риски конфиденциальности с учетом операций с персональными данными в анализируемой системе. Эти подходы не основаны непосредственно на политике конфиденциальности, но относятся к исследованиям в области оценки рисков конфиденциальности.

Специалисты института NIST предложили методологию оценки рисков конфиденциальности PRAM [13], которая основана на ручной идентификации требований конфиденциальности к анализируемой системе и связанных с ними рисков конфиденциальности. Методология оценки включает оценку вероятности (по шкале от 0 до 10) и воздействия (с точки зрения различных затрат, которые следует суммировать) каждого риска, а затем расчет (как произведение воздействия и вероятности) и определение приоритетности рисков.

В публикации [14] предлагается подход к оценке рисков конфиденциальности, основанный на деревьях угроз. Деревья построены на основе информации о системе, личных данных, соответствующих источниках риска, соответствующих событиях и их влиянии на конфиденциальность. Узлы дерева угроз представлены в виде троек, включающих персональные данные, компонент системы и источник риска. Корневой узел дерева угроз соответствует нарушению конфиденциальности. Листовые узлы соответствуют использованию данных наиболее вероятным источником риска. Настройки конфиденциальности пользователей также учитываются при расчете вероятности нарушения конфиденциальности.

Результаты анализа рассмотренных работ представлены в таблице 1.

Хотя существует множество исследований, посвященных анализу конфиденциальности и относящихся к трем упомянутым группам, нет комплексного исследования, охватывающего все три группы из анализа представленных политик конфиденциальности.

Стоит отдельно упомянуть работу [15], в которой авторы рассматривают проблему расчета рисков конфиденциальности на основе анализа политик конфиденциальности, решение которой позволит пользователям и организациям понять, какое влияние на конфиденциальность эти политики могут оказать. Авторы предлагают подход, который включает в себя сначала анализ текста политики конфиденциальности, представленной на естественном языке, генерацию и автоматическую обработку онтологии для каждой политики, указанной на естественном языке с использованием NLP, и окончательный расчет рисков конфиденциальности с использованием сгенерированных онтологий.

Таблица 1 – Сравнительный анализ работ

Описание аспектов конфиденциальности из политики конфиденциальности	Формализация политики конфиденциальности	Оценка риска для персональных данных	Генерация онтологий
<ul style="list-style-type: none"> – NLP: TF-IDF для построения вектора признаков; SVC для обнаружения практики конфиденциальности. – Аннотированный корпус политик конфиденциальности APP-350. – Ограничено приложениями для Android. 	–	–	–
<ul style="list-style-type: none"> – Краудсорсинг, ML, NLP. – Автоматическая аннотация политик конфиденциальности. – 115 аннотированных политик конфиденциальности. 	Создание онтологии для формального представления политик.	–	+
<ul style="list-style-type: none"> – Текст анализируется и онтология генерируется вручную. – Позволяет проверить соответствие политики GDPR. 	Онтология	–	Онтология PrOnto

Продолжение таблицы 1

Описание аспектов конфиденциальности из политики конфиденциальности	Формализация политики конфиденциальности	Оценка риска для персональных данных	Генерация онтологий
Построение онтологии политики конфиденциальности на основе ручной обработки текста.	Онтология	–	– Онтология генерируется вручную. – Подход основан на вопросах компетенции.
– ML: линейная регрессия и нейронные сети. – Автоматическое определение вариантов отказа. – Требуется маркированный набор данных. Авторы разместили набор данных вручную.	–	–	–
– NLP, модели включения фраз и модели машинного обучения (логистическая регрессия, линейная SVM, random forest, наивный байесовский алгоритм и ближайший сосед). – Автоматическое определение вариантов отказа от сбора. – Требуется маркированный набор данных. Авторы использовали набор данных из [5].	–	–	–
–	– Машиночитаемый язык, включающий терминологию и набор правил авторизации (действия разрешить и запретить). – Позволяет формализовать политику, чтобы указать, какие типы РП, для каких целей и для каких пользователей могут использоваться.	–	–
–	– Язык конфиденциальности, основанный на модели, включающей пользователей/группы, данные, к которым осуществляется доступ, цели доступа и режимы доступа. – Позволяет формализовать правила контроля доступа и автоматизировать выполнение этих правил.	–	–

Продолжение таблицы 1

Описание аспектов конфиденциальности из политики конфиденциальности	Формализация политики конфиденциальности	Оценка риска для персональных данных	Генерация онтологий
—	<ul style="list-style-type: none"> — Подход, основанный на языке DHP. Язык включает набор терминов и правил. — Позволяет показать пользователям, кто и на каких условиях может обрабатывать их личные данные, принимать и реализовывать решения относительно запроса доступа. — Политика должна разрабатываться для каждого нового продукта. 	—	—
—	Подход на основе языка PILOT.	Позволяет оценить риски, связанные с конфиденциальностью, если политика указана с помощью PILOT.	—
—	<ul style="list-style-type: none"> — Подход, основанный на LPL. — Позволяет различать источник и получателя данных. — Позволяет формировать политики конфиденциальности с учетом целей работы с данными. — Гарантирует удобочитаемость многоуровневых политик конфиденциальности. — Предлагаемая формулировка не охватывает все аспекты конфиденциальности. 	—	—
—	—	<p>Качественная оценка на основе анкет.</p> <p>Непосредственно к политике конфиденциальности не применяется.</p>	—
—	—	<ul style="list-style-type: none"> — Основан на деревьях угроз. — Деревья угроз формируются вручную. 	—

Продолжение таблицы 1

Описание аспектов конфиденциальности из политики конфиденциальности	Формализация политики конфиденциальности	Оценка риска для персональных данных	Генерация онтологий
Использование NLP для извлечения аспектов использования данных.	Онтология	Автоматический расчет рисков конфиденциальности на основе онтологии.	Онтология P2Onto

Авторы [15] на основе предыдущих работ предложили подход, который применим для формализации и оценки угроз персональным данным. Стоит отметить, что данный подход был протестирован авторами вручную на нескольких политиках безопасности и дал определенный результат. В связи с этим данный подход был выбран в качестве базового для построения системы формализации политик безопасности.

1.2 Онтологическое представление политик безопасности

Входными данными для предлагаемой процедуры оценки рисков конфиденциальности является политика конфиденциальности, доступная конечному пользователю службы или устройства. Поскольку в большинстве случаев эти документы содержат информацию об использовании персональных данных в неструктурированной форме, необходимо создать формальное описание данных, представленных в тексте, для применения любых дальнейших процедур оценки. Авторы [15] предлагают использовать онтологию в качестве формального представления действий по обработке политик и их особенностей, необходимых для выполнения оценки риска. Выбор формализации на основе онтологий объясняется возможностью определения основных понятий, сущностей, их свойств и семантических отношений между ними как для человека, так и для машинного чтения и многократного использования. Таким образом, предлагаемый авторами подход включает следующие шаги:

- 1) создание базовой многоцветовой онтологии P2Onto, которая описыва-

ет основные аспекты сценариев использования персональных данных и служит основой для установления процедур расчета рисков;

2) отображение текста политики конфиденциальности в базовую онтологию P2Onto;

3) расчет оценки риска на основе сгенерированного онтологического представления и алгоритмов, указанных для онтологии P2Onto.

Таким образом, ключевым элементом предлагаемого подхода является онтология P2Onto, которая описывает различные аспекты обработки персональных данных, такие как «First-party Collection/Use», «Third-party Collection/Sharing» и другие, и обеспечивает формальную основу для процедуры оценки рисков, и, которая также учитывает концепции и категории при вычислении оценки риска. На рисунке 1 представлен порядок оценки рисков, предложенный авторами [15].

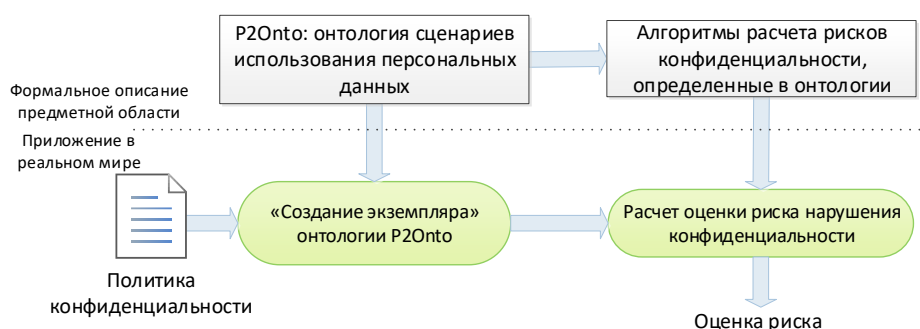


Рисунок 1 – Общая схема процедуры оценки риска

Онтология P2Onto призвана обеспечить формальную основу для процедуры оценки риска и может использоваться для проверки и объяснения полученных оценок риска. В ней описываются различные аспекты обработки персональных данных, участвующие в процессе субъекты и устанавливаются семантические отношения. Согласно процессу проектирования онтологий на основе политик конфиденциальности, предложенному в [6], построение онтологии требует сначала идентификации основных сценариев использо-

вания персональных данных и установления их характеристик, соответствующих задаче анализа. На рисунке 2 показана схема потока проектирования онтологии P2Onto.

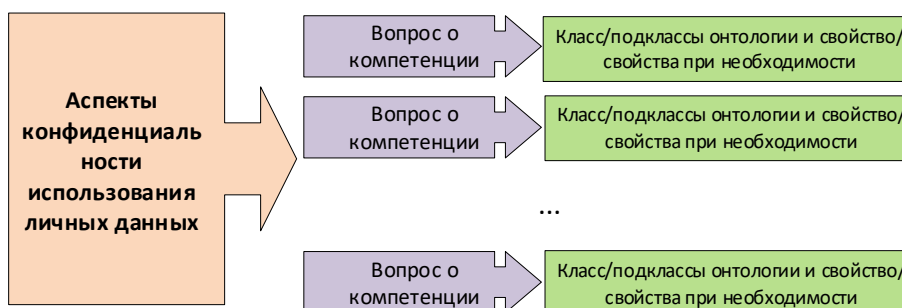


Рисунок 2 – P2Onto процесс проектирования онтологии

Авторы [15] применяют сценарии и аспекты использования персональных данных, определенные экспертами в предметной области, которые проанализировали существующие политики конфиденциальности и соответствующие правовые нормы и требования, такие как COPPA [16] и правила конфиденциальности HIPAA [17], широко используемые в исследованиях [3], [6] и [18]:

- «First-party Collection/Use» – характеризует, какие личные данные собирает поставщик услуг, управляя устройством, веб-сайтом или приложением, как они собираются, каковы правовые основания и цели сбора данных.

- «Third-party Collection/Sharing» – характеризует все вопросы, касающиеся процедур обмена данными, включая форму обмена данными – агрегированные, анонимные или необработанные.

- «Data Security» – описывает механизмы безопасности, как технические, так и организационные, используемые для защиты данных.

- «Data Retention» – характеризует временные рамки обработки и хранения персональных данных.

- «Data Aggregation» – определяет, собирает ли поставщик услуг лич-

ные данные.

- «Privacy Settings» – определяет доступные инструменты и варианты для конечного пользователя, чтобы ограничить объем собираемых персональных данных (вопросы согласия/отказа при сборе персональных данных).

- «User Choice/Control» – определяет инструменты и механизмы, предоставляемые пользователю для манипулирования личными данными – доступ, редактирование и удаление.

- «Breach Notification» – определяет инструменты и механизмы, которые поставщик услуг использует для информирования о нарушении конфиденциальности личных данных.

- «Policy Change» – определяет, какие инструменты и механизмы использует поставщик услуг для информирования конечного пользователя об изменениях в политике конфиденциальности и возможных реакциях, доступных конечному пользователю.

- «Do Not Track» – описывает, как обрабатываются сигнал «не отслеживать».

- «International and Specific Audience» – описывает различные вопросы, связанные с обработкой персональных данных особой аудитории, такой как дети, и граждане определенных государств и регионов.

Благодаря анализу этих сценариев использования персональных данных и их аспектов конфиденциальности, авторами было выделено четыре общих класса – данные, действия, агент и механизм, которые образуют основу для описания сценариев использования персональных данных, остальные классы используются для определения их свойств.

Данные – это суперкласс, который используется для определения категорий личных и неличных данных. Авторы следуют определению GDPR, чтобы указать типы персональных данных, которые описываются как «любая информация, относящаяся к идентифицированному или идентифицируемому физическому лицу (субъекту данных); идентифицируемое физическое

лицо – это лицо, которое может быть идентифицировано прямо или косвенно, в частности, посредством ссылки на идентификатор, такой как имя, идентификационный номер, данные о местоположении, онлайн-идентификатор или один или несколько факторов, специфичных для физической, физиологической, генетической, ментальной, экономической, культурной или социальной идентичности человека» [1], [19]. Это позволило определить такие подклассы персональных данных, как «User_Account_Data», включающие информацию о входе в систему, аватар пользователя, электронную почту, физический адрес, «User_Device_Info» и «User_App_Info», содержащие данные о пользовательском устройстве и приложениях, такие как версия, модель, время обновления и т.д. Также авторы обрисовали в общих чертах «Tracking_Data», чтобы указать данные, которые могут использоваться для отслеживания пользователя, такие как IP-адрес, файлы cookie, отпечаток браузера, чтобы иметь возможность оценить риски для сценария «Do Not Track», и представили подкласс «Service_Data», который используется для указания конкретных данных об обслуживании и работе устройства, например, блокировке и разблокировке, яркости экрана и т.д., которые могут использоваться для определения привычек и стиля жизни пользователя. Подробная иерархия классов данных, включая иерархию конфиденциальных данных, показана на рисунке 3.

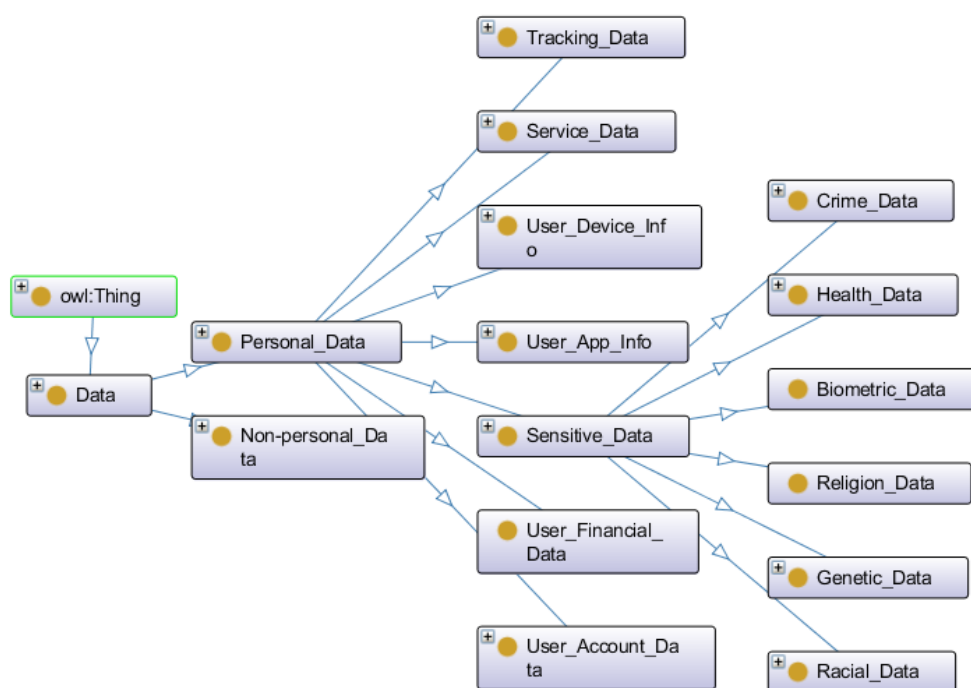


Рисунок 3 – Иерархия классов данных

Следует отметить, что класс «Non_Personal_Data» используется для описания неличных данных, возникающих при получении персональных данных посредством анонимизации или агрегации персональных данных. Знание того, сколько типов данных – идентифицируемых и нет – собираются о конкретном пользователе устройства, имеет важное значение в процедуре оценки рисков.

Как следует из списка аспектов конфиденциальности использования персональных данных, некоторые аспекты напрямую связаны с обработкой данных, например сбор, обработка, совместное использование, хранение или безопасность данных, в то время как другие относятся к деятельности, которая косвенно связана с обработкой данных, например уведомления в случае изменения политики или нарушения данных, предоставление доступа, прав редактирования, удаления и т.д. По этой причине авторами были выделены два разных подкласса класса активности – «Data_Activity» и «Control_Activity». На рисунке 4 показана иерархия подклассов «Activity».

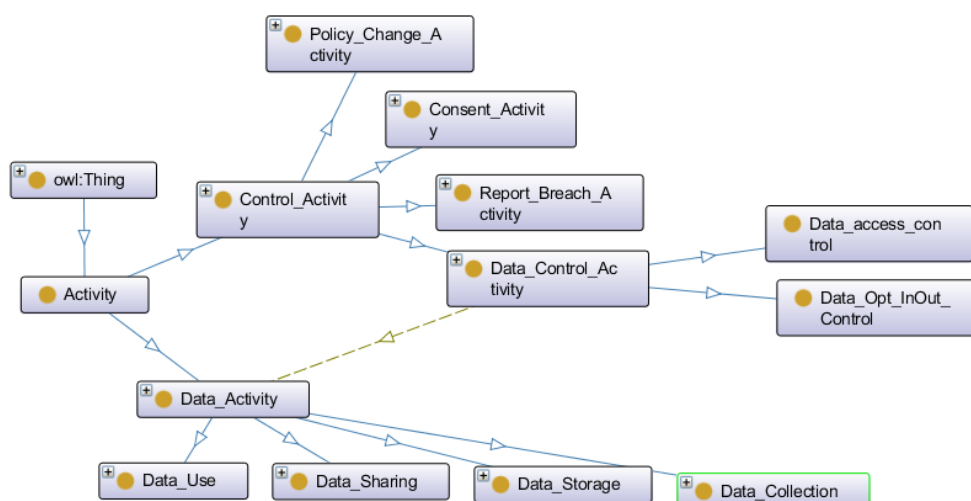


Рисунок 4 – Иерархия классов активности

Класс «Data_Activity» – это общий класс для определения различных типов операций по обработке данных. Несмотря на то, что эти действия имеют свои отличительные характеристики, можно выделить общие черты, такие как цель операций с данными, формат обрабатываемых данных – анонимные или необработанные, правовая основа для обработки данных и контролирующие лица. На рисунке 5 показаны наиболее важные классы, относящиеся к деятельности по обработке данных. Цель обработки данных является важной концепцией при оценке рисков конфиденциальности, и авторы выделили следующие цели обработки данных: предоставление услуг, реклама и маркетинг, аналитика и исследования, персонализация, безопасность, слияние и поглощение, соответствие законодательству, другое и «не определено». Каждый из них представляет собой отдельный подкласс.




Рисунок 5 – Контекст Data_Activity

Чтобы указать владельца данных, обработчика данных, а также других третьих сторон, участвующих в обработке данных, используется класс «Agent», изображенный на рисунке 6. Авторы предлагают повторно использовать эту концепцию из онтологии PROV-O, которая определяет концепт «Agent» как субъект, который несет некоторую форму ответственности за происходящую деятельность, за наличие сущности или за деятельность другого агента [20]. Эта концепция позволяет указать случаи, когда данные собираются от третьих сторон, таких как социальные сети, общедоступные источники с открытым исходным кодом. Класс «Agent» также используется для выявления случаев, когда данные собираются от посторонних лиц, то есть людей, которые не владеют устройством или услугой и с большой вероятностью не дают согласия на обработку данных.




Рисунок 6 – Иерархия классов агентов

Класс «Mechanism» – это общий класс, который используется для описания различных инструментов, опций, механизмов и интерфейсов, поддерживающих реализацию действий – сбор данных, совместное использование, использование, уведомление в случае изменения политики или нарушения данных. Он используется для характеристики таких свойств, как режим обработки (автоматический или нет), детали реализации деятельности, такие как уведомление по электронной почте или на веб-сайте, доступ к данным через приложение или через конкретный запрос по почте и т.д.

Все упомянутые выше классы связаны друг с другом с помощью

свойств, определяющих семантические отношения между ними. На рисунке 6 показаны основные концепции и свойства, относящиеся к сценариям использования и сохранения данных. Стрелки соответствуют свойствам, связывающим сущности, их цвет зависит от их типа. На рисунке 7 сущности, отмеченные желтыми точками, являются классами, а сущности, отмеченные фиолетовым ромбом, - это объекты, то есть текстовые отрывки, обнаруженные в политике конфиденциальности.




Рисунок 7 – Сценарии использования и сохранения данных

1.3 Алгоритм оценки рисков на основе онтологического представления

Алгоритм оценки рисков конфиденциальности принимает в качестве входных данных онтологию политики конфиденциальности, описывающую 11 сценариев использования.

Основная идея алгоритма заключается в том, что типы персональных данных и их количество определяют основу оценки риска для персональных данных. Другие аспекты, указанные в политике конфиденциальности, такие как цель, правовая основа и варианты подписки/отказа, могут только увеличивать или уменьшать их. Формализующий алгоритм представлен в статье [15].

Общая оценка риска на основе анализа онтологии рассчитывается по

формуле (1):

$$\text{PrivacyRiskScore} = \sum_i w_i \cdot \text{UsageScenarioRiskScore}_i, \sum_i w_i = 1, \quad (1)$$

где w_i – весовой коэффициент, определяющий влияние оценки риска i -го сценария использования данных.

В текущей версии все w_i равны друг другу, а общая оценка риска рассчитывается по формуле (2):

$$\text{PrivacyRiskScore} = \frac{1}{n} \sum_{i=1}^n w_i \cdot \text{UsageScenarioRiskScore}_i, \quad (2)$$

где n – количество анализируемых сценариев использования данных.

Расчет оценки риска конфиденциальности RiskScoreBase основан на критичности типов персональных данных и присвоенных им весах, представленных в таблице 2. Идея алгоритма расчета риска конфиденциальности RiskScoreBase заключается в определении типа персональных данных с наивысшей критичностью, присутствии этого типа в тексте политики конфиденциальности, а затем увеличении риска в зависимости от количества различных типов личных данных. Если в тексте политики присутствуют все типы персональных данных, то риски увеличиваются вдвое. Оценка риска увеличивается логарифмически, чтобы избежать быстрого роста оценки риска.

Таблица 2 – Категории персональных данных, их важность и вес

Классы и подклассы онтологии	Категории (класс)	Критичность типа ПД	Влияние категории
Data	Non Personal Data	0	0,0
	Service Data	3	0,9
	Tracking Data	4	1,3
	User Device Data	2	0,4

Продолжение таблицы 2

Классы и подклассы онтологии	Категории (класс)	Критичность типа ПД	Влияние категории
	App Data	2	0,4
	Sensitive Data	5	2,2
	User Financial Info	4	1,7
	User Account Data	2	0,4
	Other	3	1,3
	Not defined	3	1,3

Авторы [15] считают, что эта онтология может служить основой для разработки интерактивных моделей визуализации на основе графов, нацеленных на объяснение рисков конфиденциальности для конечного пользователя в ясной и удобочитаемой форме.

1.4 Постановка задачи

В связи с растущей актуальностью вопросов защиты персональных данных как никогда важными становятся методы формализации политик безопасности и оценки рисков при согласии пользователя на передачу личных данных. Рассмотренные работы в данной области продемонстрировали возможность формализации политик безопасности, а также оценки рисков при согласии с политикой конфиденциальности. Однако, пока не было предложено полностью автоматизированного решения для формализации политик безопасности и оценки рисков. В связи с этим актуальна проблема автоматизации предложенных подходов.

Таким образом задачей выпускной квалификационной работы является разработка методик и инструментов для сбора и аннотирования данных для поддержки системы формализации политик безопасности, которая в перспективе может быть использована при оценке рисков конфиденциальности.

2 Проектирование инструментария

2.1 Применение строгих методов анализа текста для формализации политик безопасности

Вопреки тенденциям на использование технологий машинного обучения для формализации политик безопасности, были сделаны попытки осуществить формализацию с помощью различных алгоритмов кластеризации.

Основанием для проведения данных экспериментов послужила особенность моделей построенных глубококом обучении – необходимость наличия размеченной выборки данных для обучения. Сбор данных для этих целей – трудоемкий процесс, равно как и аннотирование собранных данных.

Поэтому были протестированы различные алгоритмы кластеризации и тематического моделирования. Также была сделана попытка анализа политик безопасности на основе частеречной разметки и контекстно-свободных грамматик.

2.1.1 Статистические модели текстовых документов

В рамках экспериментов со строгими методами анализа текстов были протестированы две модели векторизованного представления текста – Bag-of-Words и TF-IDF. Модель Bag-of-Words представляет документ в виде матрицы, представленной на рисунке 8.

		Слова		
Параграфы		w_1	\dots	w_n
	d_1	count (w_1, d_1)	\dots	count (w_n, d_1)
	\dots	\dots	\dots	\dots
	d_n	count (w_1, d_n)	\dots	count (w_n, d_n)

Рисунок 8 – Bag-of-Words матрица

Здесь слова каждого абзаца подсчитываются и сопоставляются с абзацами, в которых они встретились. Модель TF-IDF представляет документ в виде матрицы, представленной на рисунке 9. Формула (3) показывает, как можно получить метрику TF-IDF.

$$\text{tfidf}(t, d, D) = \frac{n_t}{\sum_k n_k} \times \log \frac{|D|}{|\{d_i \in D : t \in d_i\}|}, \quad (3)$$

где t – термин или слово,

d – конкретный абзац,

D – набор абзацев.

Итак, модель TF-IDF придает больший вес словам которые использованы меньше раз. Это может быть полезно, когда тексты схожи с точки зрения используемых слов, как в случае с политиками безопасности.

		Слова		
		w_1	\dots	w_n
Параграфы	d_1	$\text{tfidf}(w_1, d_1, D)$	\dots	$\text{tfidf}(w_n, d_1, D)$
	\dots	\dots	\dots	\dots
	d_n	$\text{tfidf}(w_1, d_n, D)$	\dots	$\text{tfidf}(w_n, d_n, D)$

Рисунок 9 – Матрица TF-IDF

2.1.2 Подход основанный на латентно-семантическом анализе текста

Современные методы кластеризации текстов позволяют определять тематику текстов с высокой точностью. Однако, большинство из этих методов принимают тексты с самыми разными темами как вход для алгоритмов. Тексты со схожими тематиками можно проанализировать с помощью латентно-семантического анализа дважды: группировать тексты по темам один раз, и

предоставить еще более детальное разделение их по подтемам во второй раз. Такой подход можно использовать для более точной классификации абзацев с точки зрения их характеристик и аспектов использования персональных данных. Следует отметить, что латентно-семантический поиск сильно зависит от глобального текстового контекста с потерями информации о локальных контекстных отношениях между словами. Были выделены девять тем конфиденциальности, которые следует сопоставить с абзацами согласия пользователя сайта – «сбор личных данных», «сбор данных третьими лицами», «управление личными данными», «механизмы защиты персональных данных» и другие. Очевидно, что аспекты обращения с данными состоят из нескольких слов, и в некоторых случаях перекрываются. На основании этих фактов была выдвинута гипотеза о том, что латентно-семантический поиск способен обнаружить даже незначительную разницу в тексте абзацев при пропуске частых слов. Перед применением латентно-семантического анализа требуется предварительная обработка входных данных. Обычно эта процедура включает в себя очистку данных, удаление гиперссылок, пунктуации и т.д. Также текст политик конфиденциальности был разбит на массив абзацев. Каждый абзац был преобразован в массив слов, которые он содержит. Следующим шагом было удаление наиболее частых, но не столь значимых слов, так называемых стоп-слов. Наконец была применена операция стемминга, чтобы рассматривать только основную часть всех слов полученных от единого корня.

Пусть A – это матрица абзацев и слов, тогда формула (4) будет следующей:

$$A = U \times S \times V^T, \quad (4)$$

где A – матрица слов и параграфов;

U – ортонормированная матрица U ;

V – ортонормированная матрица V ;

S – диагональная матрица S , значения которой сингулярны для A .

После того, как матрица была разделена на три компоненты, матрица U содержит n -мерные векторы, которые можно интерпретировать как координаты в n -мерном пространстве [21]. Документы могут быть распределены по кластерам по значениям этих координат. Проведенные эксперименты с латентно-семантическим анализом выполнялись с использованием набора данных с открытым исходным кодом, который включает 115 политик безопасности, которые были размечены вручную, и все абзацы присвоены одному или нескольким сценариям использования персональных данных [18]. Результаты экспериментов для модели Bag-of-Words представлены в таблице 3, в ней показаны полученные кластеры и соответствующие значения координат.

Таблица 3 – Кластеры политик безопасности для модели Bag-of-Words

№	Координата 1	Координата 2	Координата 3	Координата 4
0	0.634 inform	0.280 may	0.276 use	0.232 servic
1	0.202 cooki	0.466 inform	0.336 site	0.257 use
2	0.524 privaci	0.433 polici	0.388 cooki	0.219 site
3	-0.589 servic	0.344 site	0.244 parti	-0.240 third
4	-0.504 parti	0.486 third	-0.449 servic	0.235 advertis
5	-0.594 site	0.278 cooki	0.272 websit	0.264 privaci
6	-0.326 may	0.311 site	0.307 servic	-0.293 email
7	-0.437 may	-0.369 advertis	0.345 person	0.319 cooki
8	0.501 may	-0.315 email	-0.281 use	-0.264 address
9	-0.488 user	-0.384 use	0.310 provid	-0.301 websit

Как видно, результаты противоречивы, поэтому трудно понять, какая из тем каким смыслом обладает. Затем рассчитывалась метрика принадлежности к теме с помощью библиотеки Gensim [22] и результаты снова не были

обнадеживающими. Результаты расчета метрики принадлежности кластеру представлены в таблице 4.

Таблица 4 – Принадлежность кластерам

Topic	0	1	2	3	4
Affiliation	2.27	-0.8	0.15	-0.22	-1.2
Topic	5	6	7	8	9
Affiliation	-0.17	-0.15	-0.2	0.22	-0.07

Другие результаты с параграфами, относящимися к другому аспекту обращения с данными, были почти такими же. Результаты представлены в таблице 5.

Таблица 5 – Принадлежность кластерам

Topic	0	1	2	3	4
Affiliation	2.59	-0.76	0.64	0.74	0.13
Topic	5	6	7	8	9
Affiliation	0.14	-0.12	0.23	0.12	0.41

Все протестированные абзацы были сопоставлены с кластером 0, что не может быть верным так как абзацы относились к заведомо разным аспектам обращения с персональными данными.

Результаты экспериментов для модели TF-IDF представлены далее, в таблице 6. Также показывались десять кластеров и координаты в семантическом пространстве. И, как в первом случае с «мешком слов», по значениям координат невозможно судить о теме кластера.

Таблица 6 – Кластеры политик безопасности для модели TF-IDF

№	Координата 1	Координата 2	Координата 3	Координата 4
0	0.202 cooki	0.2 may	0.198 inform	0.198 site
1	0.573 cooki	0.262 browser	0.195 advertis	0.182 web
2	-0.406 media	0.291 cooki	0.282 health	0.279 advertis

Продолжение таблицы 6

№	Координата 1	Координата 2	Координата 3	Координата 4
3	-0.453 health	0.258 email	-0.204 kaleida	0.191 address
4	0.423 health	0.215 media	0.205 kaleida	-0.199 secur
5	-0.299 advertis	0.262 health	-0.252 media	-0.213 privaci
6	-0.325 media	0.263 polici	0.249 privaci	0.197 chang
7	0.280 cooki	-0.216 device	-0.183 health	-0.166 social
8	-0.223 advertis	-0.206 teenag	-0.206 inelig	0.176 child
9	-0.263 child	-0.26 wireless	0.245 message	0.239 parent

Результаты кластеризации снова противоречивы, поэтому трудно сказать, какая конкретная тема какой аспект политики конфиденциальности описывает. В разных темах встречаются одни и те же слова с изменением веса. Для искомых аспектов политики конфиденциальности нет тем, которые могли бы их точно описать. Затем с помощью библиотеки Gensim был рассчитан показатель принадлежности к теме, и результаты снова не были обнадеживающими. Результаты расчета аффилиации абзаца одной из политик конфиденциальности к полученным кластерам представлены в таблице 7.

Таблица 7 – Принадлежность кластерам

Topic	0	1	2	3	4
Affiliation	2.18	-0.97	-0.69	-0.27	0.65
Topic	5	6	7	8	9
Affiliation	0.98	-1.17	0.8	0.27	0.01

Результат для другого абзаца, относящегося к другой политике конфиденциальности, был почти такой же. Результаты представлены в таблице 8.

Таблица 8 – Принадлежность кластерам

Topic	0	1	2	3	4
Affiliation	1.82	0.25	0.49	0.29	-0.04
Topic	5	6	7	8	9
Affiliation	0.74	0.52	-0.04	-0.58	-1.33

Как можно заметить, результаты для модели TF-IDF аналогичны результатам модели Bag-of-Words, за исключением нескольких незначительных изменений. Все абзацы снова были сопоставлены с кластером 0, что неверно, потому что они на самом деле описывают разные сценарии использования персональных данных. Эти эксперименты позволили сделать вывод, что использование латентно-семантического анализа не дает ценной информации о содержании онлайн-согласия пользователя. Проблема может быть связана с тем, что сценарии использования персональных данных очень похожи между собой, и для того, чтобы различать разные сценарии необходимо учитывать локальный контекст.

В результате апробации алгоритма латентно-семантического анализа было выяснено, что для кластеризации экстремально схожих между собой текстов он подходит не лучшим образом.

2.1.3 Подход основанный на латентном размещении Дирихле

Для тестирования латентного размещения Дирихле был как и ранее выбран датасет OPP-115 с открытым исходным кодом [18]. В большинстве случаев аспекты относятся к абзацам текста, а некоторые абзацы относятся к нескольким категориям одновременно. На рисунке 10 показано распределение абзацев по категориям. Хорошо видно, что есть две основные категории – «Third-party Sharing/Collection» и «First-party Collection and Use», которые преобладают над остальными.

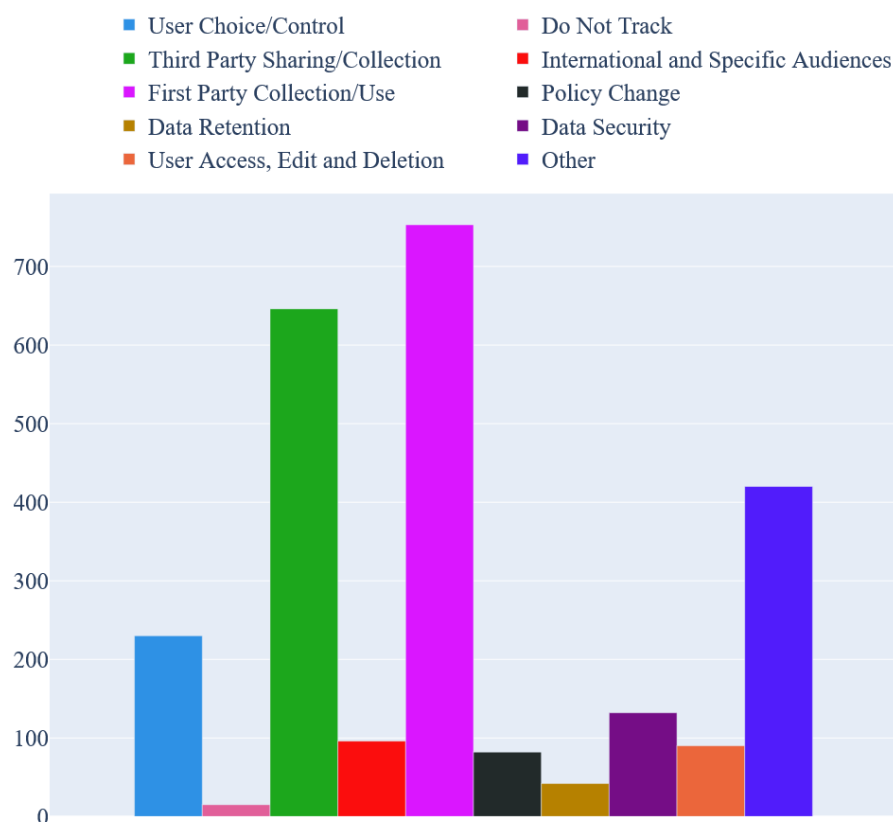


Рисунок 10 – Распределение по сценариям использования данных

Чтобы применить LDA к анализу политики конфиденциальности, тексты политик конфиденциальности были разбиты на набор абзацев. Каждый абзац был преобразован в массив слов, а затем удалены наиболее частые, но не значащие слова, так называемые стоп-слова. Также была выполнена лемматизация, чтобы обобщить некоторые слова, для получения более точных результатов.

В ходе экспериментов как и ранее были протестированы две модели векторизации текста – Bag-of-Words и TF-IDF, и оказалось, что метрика TF-IDF предоставляет более подробную информацию о сценариях использования данных, поскольку эта модель векторизации дает более высокие веса словам, которые реже используются.

Оптимальное количество кластеров, то есть семантических моделей, было определено как 15, поскольку такое значение соответствует макси-

мальному значению когерентности, рассчитанному с помощью библиотеки Gensim [10]. Важно отметить, что это число отличается от числа категорий, обозначенных создателями набора данных OPP-115.

Результаты экспериментов для модели TF-IDF показаны в таблице 9. В таблице 9 приведен список координат, которые формируют семантические модели тем. Координаты используются для составления гипотезы об использовании личных данных и сценариях их применения.

Хорошо видно, что большинство извлеченных моделей посвящено сценариям «First-Party Collection and Use» и «Third-Party Sharing/Collection». Это полностью соответствует распределению категорий в наборе данных. Абзацы различаются характеристиками семантических моделей. Например, тематическая модель 9 раскрывает варианты согласия/отказа при обмене личными данными в рекламных целях, тематическая модель 6 посвящена использованию файлов cookie первыми и третьими сторонами, некоторые тематические модели предоставляют информацию о типах собираемых личных данных: информация об учетной записи пользователя (тематическая модель 7), финансовые данные (тематическая модель 2), данные отслеживания местоположения и аналитики (тематическая модель 11). Некоторые темы, такие как тематические модели 4 и 10, раскрывают довольно специфические аспекты использования личных данных, такие как безопасность данных, включая случай, когда данные передаются третьим лицам, и уведомление в случае изменения политики. Некоторые тематические модели являются довольно общими, например, модели характеризуют очень общие проблемы, связанные со сбором данных первой стороной и сторонним совместным использованием 0,1 и 3.

Таблица 9 – Тематическое моделирование

№	Координаты семантического пространства	Возможные сценарии использования
0	service, friend, story, child, cookie, use, product, email, compromised, card	First-party collection & usage (usage of cookies, e-mail), Special audience (children)
1	schedule, channel, analytic, happy, website, gather, address, mingle, moreover, identifiable	First-party collection (identifiable user data)
2	collect, credit, card, us, address, pursuant, email, service, personal, may	First-party collection: payment credentials
3	state, united, asset, website, policy, personal, privacy, party, third, sm	Third-party sharing
4	security, personal, rating, site, u, disclosure, service, policy, physical, third	Data security (including third-party sharing)
5	party, third, child, service, cookie, personal, personally, site, company, identifiable	Third-party sharing (usage of cookies)
6	service, website, personal, site, cookie, party, third, data, use, us	First-party collection & Third-party sharing (for: services provision, usage of website data and cookies)
7	personal, service, account, information, site, device, u, may, provide, use	First-party collection: user account information
8	device, resume, message, policy, privacy, social, service, site, website, networking	Other
9	opt, collect, site, third, advertising, personal, party, service, u, privacy	First-party collection & Opt-in, opt-out for advertising
10	military, change, policy, time, site, web, page, privacy, cookie, post	Privacy policy change, including notification mechanism
11	navigating, service, google, non, adsense, nielsen, account, collect, device, privacy	First-party collection: device and location information
12	station, feedback, service, consented, java, script, merchant, cookie, child, st	Other
13	cookie, service, third, party, site, website, california, flash, use, technology	Third-party sharing & Special audience: California residents
14	child, forum, trade, age, pii, conversation, chat, branded, personal	Special audience: children

Однако необходимо учитывать, что политики конфиденциальности в большинстве случаев являются очень общими и неструктурированными, они не содержат четкой спецификации действий по обработке данных. Для некоторых тематических моделей было сложно определить аспекты сценариев использования, они были объединены в группу «Other».

Также стоит отметить, что не было выявлено моделей, посвященных хранению данных и аспектам доступа, редактирования и удаления данных.

Это могло произойти из-за того, что количество абзацев, содержащих эту информацию, невелико, и они семантически довольно близки к сценарию «First-Party Collection and Use». Напротив, были найдены темы посвященные аспектам «International and Special Audience», «Data Security» и «Privacy Policy Change», хотя количество их вхождений в наборе данных сопоставимо с «Data Retention» и «User Access, Edit and Deletion».

Используя извлеченные тематические модели, было проанализировано содержание политик конфиденциальности и вручную оценена точность кластеризации абзацев для набора выбранных политик. Например, для политики конфиденциальности Xiaomi [11] была получена точность 69%. На рисунке 11 показано распределение семантических тематических моделей абзацев в тексте политики конфиденциальности Xiaomi. Отчетливо видно, что большая часть документа посвящена описанию различных аспектов «First-Party Collection and Use» – указанию, какие типы данных собираются, есть ли какие-либо варианты выбора/отказа. Полученные результаты также сравнивались с результатами [5] с помощью онлайн-инструмента Pribot [23]. Сравнительный анализ показал, что LDA выявило все основные аспекты использования персональных данных, за исключением одной целевой детской аудитории. Когда была перепроверена политика Xiaomi, выяснилось, что данному аспекту было посвящено лишь одно предложение.




Рисунок 11 – Распределение по сценариям использования данных, полученное с помощью LDA

2.1.4 Подход основанный на применении контекстно-свободных грамматик и синонимическом поиске

Другой предложенный подход – подход, основанный на анализе с помощью контекстно-свободных грамматик и синонимического поиска. Синонимический поиск в данном случае – это подмена ключевых слов и их синонимов метками, например «__FP_A__» означает, что это слово и его синонимы считаются акторами (первым лицом). Этот метод можно применить ко многим другим концепциям. Например, сообщения электронной почты, аватары, местоположение также могут быть объектами и синонимами абстрактной метки «__CN__», которая означает существительное сбора или объект сбора. Так все ключевые слова могут быть преобразованы в их смыслы в

контексте предметной области. Маркировка выполняется просто, все слова, совпадающие с пулами, заменяются метками этих пулов.

Предварительная обработка данных в данном случае состоит из токенизации и лемматизации для более гибкой замены слов на метки их пулов.

При анализе пользовательского согласия сайта недостаточно найти ключевые слова, относящиеся к разным типам персональных данных, например цель и правовую основу распознать гораздо сложнее. Следующий шаг – установить отношения между словами в предложениях, чтобы можно было определенно сказать, что ярлыки пулов синонимов связаны друг с другом и формируют логическая цепочку. Один из возможных способов определения отношений слов в тексте на естественном языке – это синтаксический анализ предложения, основанный на частеречной разметке [24]. Имея размеченное по частям речи предложение, парсер грамматики NLTK [25] строит деревья предложений по правилам грамматики. Одно из таких деревьев в обозначениях NLTK можно увидеть на рисунке 12 [25].

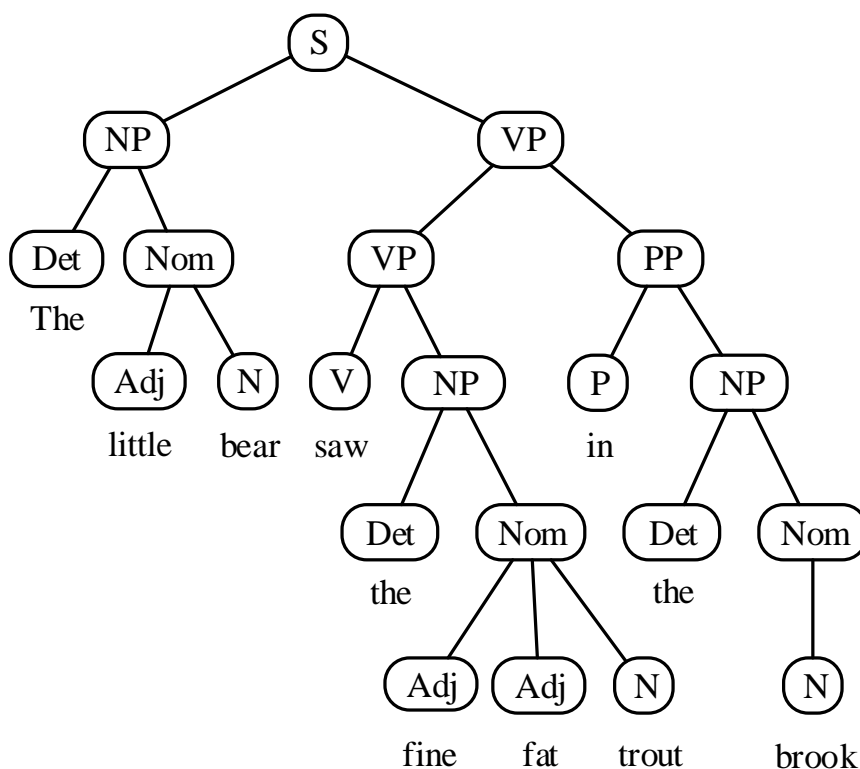


Рисунок 12 – Пример грамматического разбора

Здесь «S» – основа предложения, «NP» – именная фраза, «VP» – глагольная фраза, «Adj» – прилагательное, «Nom» – именное словосочетание, «PP» – предлог фразы, «Det» – артикль, «V» – глагол, «N» – существительное, «P» – предлог.

В предлагаемом подходе немного другая грамматическая запись. Созданная грамматика представлена в (5).

$$\left\{ \begin{array}{l} D \rightarrow S \mid S D \mid S U D \\ S \rightarrow NPG \text{ } VBG \\ VPG \rightarrow VP \mid VP \text{ } VPG \mid VP \text{ } U \text{ } VPG \\ NPG \rightarrow NP \mid NP \text{ } NPG \mid NP \text{ } U \text{ } NPG \\ AJPG \rightarrow AJ \mid AJ \text{ } APG \mid AJ \text{ } U \text{ } APG \\ AVPG \rightarrow AV \mid AV \text{ } APG \mid AV \text{ } U \text{ } APG \\ VP \rightarrow V \text{ } APG \mid V \text{ } PPG \mid V \text{ } PP \text{ } APG \\ NP \rightarrow NOM \mid DET \text{ } NOM \\ NOM \rightarrow N \mid AJPG \text{ } N \\ PP \rightarrow NPG \mid P \text{ } NPG \end{array} \right. , \quad (5)$$

где D – документ,

SB – синтаксическая основа предложения с его зависимостями,

U – союз,

NPG – группа именных фраз,

VPG – группа глагольных фраз,

AJPG – группа однородных прилагательных,

AVPG – группа однородных наречий,

PPG – группа однородных дополнений,

VP – глагольная группа,

NP – именная группа,

NOM – номинальная группа,

Р – предлог,
 AJ – прилагательное,
 AV – наречие,
 PP – существительное с предлогом,
 N – существительное,
 V – глагол,
 DET – определяющее слово.

Грамматика из формулы (5) позволяет рекурсивно выделять основу предложения и последовательности глагола, существительного, прилагательного, наречия и т.д. Это все еще не идеальное решение, но способное обрабатывать довольно сложные предложения в политиках безопасности. Этот подход требует использования пулов синонимов, которые соответствуют различным ключевым словам. Поэтому в грамматику включены метки пулов синонимов, привязанных к части речи. Метки пулов вручную назначены частям речи для связи их с нотацией частей речи NLTK, это показано в формуле (6).

$$\left\{ \begin{array}{l} U \rightarrow \text{NLTK_CC} \\ \text{DET} \rightarrow \text{NLTK_DT} \\ \text{AJ} \rightarrow \text{NLTK_JJ} \\ \text{AV} \rightarrow \text{NLTK_RB} \\ \text{N} \rightarrow \text{__CN__} \mid \text{__FP_A__} \mid \text{__TP_A__} \mid \text{NLTK_N} \\ \text{V} \rightarrow \text{__CV__} \mid \text{NLTK_V} \end{array} \right. , \quad (6)$$

где NLTK_CC – соединение NLTK,
 NLTK_N – все формы существительных NLTK,
 NLTK_ – все формы глаголов NLTK,
 NLTK_DET – определители NLTK,
 NLTK_RB – все формы наречий NLTK,
 __FP_A__ – метка актора-обладателя персональных данных,

__TP_A__ – третья сторона,
 __CV__ – глагол сбора,
 __CN__ – существительное сбора.

Теги, начинающиеся с подчеркивания, являются метками пулов синонимов. Синтаксический анализ выполняет библиотека NLTK. На основе предложенной грамматики, описанной (5) и (6) и меток пулов было построено дерево тестового предложения, результат на рисунке 13.




Рисунок 13 – Дерево грамматического разбора

Когда было построено дерево предложений, последовательность меток ключевых слов может быть распознана. В этом случае представленная на рисунке 13, последовательность «__FP_A__», «__CV__», «__CN__» хоро-

шо видна. Такие простейшие последовательности, раскрывают значения частей предложения и могут быть объединены в список, после этого весь смысл документов будет описан этим списком. Сочетание маркировки ключевых слов и синтаксического анализа дает значения ключевых слов с отношениями между этими словами, определенными в виде древовидных структур. Дерево структура данных более гибкая, чем строка предложения, деревья и особенно поддеревья показывают важные отношения между словами. Запросы к таким структурам могут дать необходимую информацию для построения логических последовательностей действующих лиц, их действий, субъектов этих действий и, наконец, обстоятельств. Предлагаемый подход определенно имеет такие недостатки, как низкая производительность, вручную определенные пулы синонимов и т.д.

2.1.5 Выводы по строгим методам текстового анализа

Эксперименты показали, что оба рассмотренных метода имеют как преимущества, так и определенные недостатки. Хотя предложенные подходы, оказались противоречивыми, окончательные результаты заслуживают внимания. Подход с латентно-семантическим поиском оказался не слишком эффективным. Однако, подход основанный на грамматическом анализе предложений и синонимическом поиске дал определенные результаты. Хоть он и не является производительным, с его помощью возможно производить выделение логических цепочек из предложений для получения более формального описания политик безопасности нежели их текстовые варианты. Алгоритм LDA показал наилучшие результаты, однако этих результатов все же недостаточно для выявления таких тонких сущностей как атрибуты классов, представленных в онтологии из работы [15].

Исходя из проведенных исследований стало понятно, что более предпочтительным вариантом решения задачи будет подход с применением моделей глубокого обучения. Реализация подобного проекта – комплексная задача, ее можно разделить на несколько этапов. Сначала необходимо собрать датасет,

потом разметить его для обучения модели, далее обучить модель и получить результаты. Однако, сбор датасета тоже является непростой задачей. Необходимость сбора нового датасета обусловлена еще и принятием GDPR в качестве основного документа, регулирующего обработку, хранение и использование персональных данных, в то время как существующие датасеты состоят из устаревших документов. Для того, чтобы осуществить сбор датасета необходим инструмент для поиска и скачивания веб-страниц из сети Интернет. Затем необходимо произвести очистку данных, удалить все теги со страниц, чтобы можно было передать текст аннотаторам. Все этапы сбора датасета полагаются на базу данных. Она лишена сложного объектно-реляционного моделирования, так как в ней по сути необходимо только хранить промежуточные результаты обработки текстовых материалов.

2.2 Техническое задание «Инструментарий для сбора датасета»

2.2.1 Скрейпер веб-страниц

Скачивание веб-страниц будет производиться инструментом, написанным на языке Python, с помощью библиотек можно скачивать страницы, анализировать данные содержащиеся в них, переходить по гиперссылкам и много другое. Такой инструмент позволит просматривать и сохранять содержимое страниц в автоматическом режиме без вмешательства пользователя. Таким образом, в автоматическом режиме можно сохранить и проанализировать огромное количество текстовой информации.

2.2.2 Очистка скачанных страниц политик

Для очистки страниц от кода разметки планируется использовать библиотеку `html-sanitizer`. Очистка кода необходима для того, чтобы аннотаторы могли максимально сфокусироваться на анализе текста, таким образом, получая чистый текст, они не будут отвлекаться на не имеющие значения в контексте задачи фрагменты.

2.2.3 Инструмент разметки датасета

Инструмент разметки датасета планируется реализовать с помощью веб-технологий. Серверная часть будет полагаться на приложение, написанное на языке PHP, которое будет регулировать порядок выдачи текста на аннотирование. Процесс разметки высокодинамичен, поэтому невозможно избежать написания качественной клиентской части приложения на языке javascript. Это позволит сделать работу аннотаторов максимально производительной, в одну сессию (страница не будет перезагружаться).

2.2.4 Фреймворки глубокого обучения

Аннотированный датасет должен быть легко адаптируемым для создания и тренировки модели анализа текста с использованием современных фреймворков машинного обучения, таких как Keras, PyTorch и другие. Они позволят быстро создавать классификаторы самых разных конфигураций и типов.

После того как классификатор будет сконфигурирован, останется лишь обучить его на датасете, полученном ранее.

Обученный классификатор будет способен определять различные характеристики политики безопасности и аспекты обращения с данными, что позволит в автоматическом режиме формализовать политики конфиденциальности, формировать отчеты о безопасности предоставляемого соглашения на основе алгоритмов, предложенных в [15].

2.3 Методика сбора

Планируя решение появившейся задачи, важно уделить внимание источникам данных для сбора, потому что без них невозможно будет продолжать работу. Это важно еще и потому, что необходимо будет адаптировать инструмент сбора данных под конкретные веб-ресурсы, так как на каждом из них реализована собственная html-разметка.

Исходя из ориентированности датасета на умные устройства, логич-

ным выглядит обращение к крупным торговым площадкам, так как они занимаются дистрибуцией подобных устройств. На сайтах торговых площадок можно осуществлять поиск продукции и получать данные о ней, в том числе и производителя продукции. Типовая разметка веб-страниц располагает для получения такой информации, так как существует лишь несколько вариантов наполнения страницы продукции.

Торговые площадки не предоставляют ссылки на официальные сайты производителей. Поэтому необходимо организовать поиск официальных сайтов производителей. Поисковые движки предоставляют API для поиска, однако некоторые из них являются платными, другие выдают совершенно неприемлемые результаты. С другой стороны использование поисковых движков, предназначенных для реальных пользователей, дает наилучшие результаты из возможных, скорее всего это связано с клиентоориентированностью, то есть получая запрос близкий к наименованию бренда с большей вероятностью будет выдана официальная страница производителя в сети Интернет.

Далее важной задачей является определение, какая из ссылок в результате запроса наиболее четко соответствует искомому производителю. Получение официальных веб-сайтов производителей задача на первый взгляд сложная, однако результаты ручной проверки показали, что лучшим вариантом является поисковый запрос с названием производителя и типом устройства. В таком случае веб-сайт производителя оказывается на первой странице результата поискового запроса, а если не оказывается, значит у этой компании его с очень большой вероятностью нет.

Получив ссылки предполагаемых официальных сайтов, появляется возможность получить доступ к страницам, на которые они ведут. Поиск политики безопасности на уже обнаруженном сайте производителя является тривиальной задачей. Сейчас на абсолютном большинстве сайтов в футере имеется ссылка, названная как «Privacy» или «Privacy Policy». Футер досту-

пен на любой странице сайта и является частью глобальной навигационной системы сайта, в него вынесена информация, которая пригождается не так часто как, например, информация из верхних панелей и меню, однако тем не менее эта информация важна, и помимо ссылок на политику безопасности зачастую содержит контактные данные и прочую организационную информацию.

Таким образом можно получить ссылки на политики безопасности производителей умной продукции. Далее необходимо произвести обработку скачанных политик безопасности.

2.4 Методика очистки

Очистка политик безопасности является комплексной задачей. Получив политику безопасности, необходимо удалить все теги, которые несут в себе динамику, то есть все элементы управления. Такие элементы как всплывающие, модальные, диалоговые окна тоже не могут содержать текст политики безопасности. Изображения, помещенные на странице, так же не относятся к политике безопасности. Таким образом получается, что большое количество тегов необходимо в агрессивной манере удалять еще до начала анализа страницы, так как они точно не содержат полезной информации.

Далее необходимо применить обработку, которая включала бы в себя преобразование разметки: недопустимые теги должны быть развернуты, определенные комбинации вложенных тегов должны быть заменены на более тривиальные. Также необходимо очистить теги от атрибутов, так как в них не содержится полезной информации или чего-либо способного положительно сказаться на структуре очищенного документа. Затем по всему дереву DOM осуществляется рекурсивный обход с целью слияния тегов, где это возможно, или оборачивания сырых текстов. В ходе данного этапа также производится нормализация пунктуации и настройка отступов в текстах, чтобы привести их к читабельному виду.

После указанных двух этапов очистки, следует заключительный, на ко-

тором из тегов извлекается текст, то есть параграфы, представленные в виде одной длинной строки. Это делается потому, что расставленные определенным образом переводы на новую строку могут по тем или иным причинам не подходить, и это будет более гибким решением, потому что где требуется можно применить автоматический перенос на новую строку.

2.5 Методика разметки

Ключевой в вопросе разметки является идея онтологического представления предметной области. Разметка текста – процесс интуитивный – «что вижу, то получаю». Из этого обстоятельства вытекает определенная проблематика:

- онтологическое представление сложно организовать на месте, прямо в тексте;
- разметка текста ограничена с точки зрения информативности, сложной является задача отображения текста таким образом, чтобы были видны и понятны все метки, присвоенные фрагментам текста;
- разметка текста не должна нарушать его целостное восприятие, в противном случае чтение будет затруднено;
- пересечение маркированных фрагментов текста.

Онтологическое представление это прежде всего графовое представление, при наложении нескольких базовых слоев разметки с сущностью, которая может относиться к обоим этим слоям, может возникнуть неоднозначность. Для ее разрешения необходимы дополнительные усложнения интерфейсной части. Такое усложнение может плохо сказаться на восприятии информации пользователем. Кроме того, это неоправданное усложнение и программного кода. Решение этой проблемы можно найти на уровне проектирования – совершенно не обязательно представлять разметку как онтологию. При этом может показаться, что происходит отказ от онтологического представления предметной области. Представив онтологию в виде иерархии, разъединив ее на определенных вершинах можно получить валидную иерар-

хию, которая будет гораздо органичнее укладываться в концепцию разметки текста. По завершении аннотирования можно будет обратным образом объединить иерархии, полученные в ходе аннотирования, в онтологии, тем самым выполнив требование по онтологическому представлению предметной области.

Многослойное аннотирование сложно представить каким-либо отличным образом от представленного на рисунке 14.

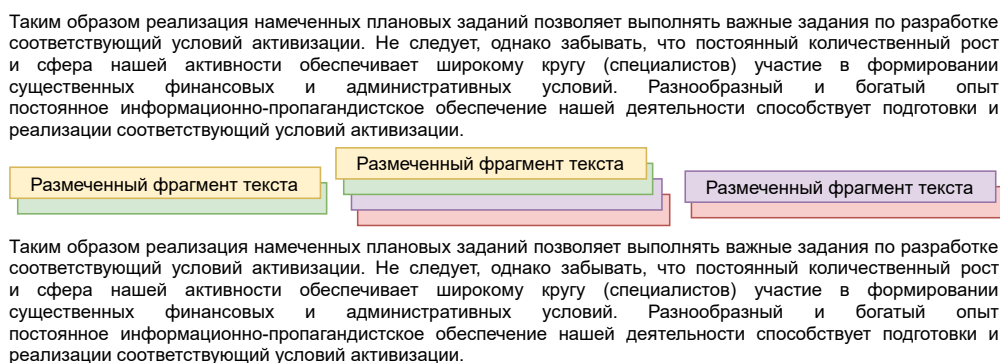


Рисунок 14 – Пример разметки текста

На данном рисунке показан макет фрагмента аннотации. При таком подходе информация о разметке не отделена от текста, представляет с ним одно целое. Использование всплывающих окон и подсказок нецелесообразно, так как они своим появлением будут перекрывать текст, мешая его восприятию. Вместо этого предлагается более статичный вариант отображения и наложения новых слоев, представленный в разделе 2.8.3.

Язык гипертекстовой разметки обладает рядом особенностей, которые препятствуют простому решению проблемы пересечения разметки. Ключевым моментом в этом является древовидное представление документа – DOM. Любое пересечение в рамках данной структуры является невалидным и соответственно не будет работоспособным. Поэтому предлагается в местах начала и окончания аннотированных фрагментов применять разбиение на 3 фрагмента. Первый – текст, который шел до выделения, текст самого выделения, текст идущий после выделения. При этом элемент документа будет

иметь глубину вложенности не более 1 уровня, что фактически означает разворот иерархии в ширину на уровне языка гипертекстовой разметки. Однако, построение иерархической структуры разметки невозможно при использовании всего лишь 1 уровня вложенности. Решение представлено на рисунке 15.




Рисунок 15 – Схема решения с учетом пересечения разметки

Расширения глубины иерархии разметки можно добиться с помощью других средств. Так как гипертекстовая разметка в данном случае не может быть адаптирована, то хранение иерархии разметки может производиться во вспомогательных структурах данных – стеках. Ассоциировав с каждым элементом разметки такой стек, можно манипулировать уровнями разметки текста без повреждения гипертекстовой разметки.

2.6 Потенциальные проблемы

Еще до решения задачи были выделены потенциальные проблемы, способные замедлить процесс разработки и сбора датасета. Потенциально возможные проблемы при реализации приложений подобного типа следующие:

- 1) блокировка из-за подозрительных заголовков браузера,
- 2) блокировка из-за слишком частого обращения с запросами,
- 3) как следствие 2-х предыдущих пунктов требование подтвердить, что это не попытка автоматического доступа (ввод captcha).
- 4) Невидимые элементы разметки,
- 5) динамически формируемые страницы торговых площадок и политик безопасности,
- 6) промахи при сборе данных из-за частично некорректных результатов поиска на торговых площадках и в поисковых движках.

Проблемы 1, 2, 3 решаются использованием разных заголовков браузера попеременно. Также отправка запросов ограничена по частоте от 2 до 6 секунд, ограничение выбирается случайным образом. Такие решения позволяют крайне редко попадать под подозрения, потому что в таком случае поведение максимально похоже на поведение реального пользователя, соответственно процент успеха при попытке получить данные с веб-страницы значительно повышается. Стоит отметить, что данные ограничения очень эффективно обходятся за счет использования прокси-серверов, которые позволяют менять ip-адрес. Еще одним важным и эффективным инструментом является профиль браузера. Он позволяет запускать безголовый браузер с определенной историей использования, будь то куки-файлы, история запросов или аутентификация в различных сервисах. Наличие такой предыстории у браузера для некоторых сайтов является доказательством, что он не находится под управлением программы.

Проблема 4 решается следующим образом. Попад на страницу политики безопасности, можно исполнить код на javascript, который загрузит на страницу библиотеку для работы с деревом DOM и удалит невидимые элементы разметки.

Проблема 5 решается использованием безголового браузера, который является полнофункциональным с точки зрения воспроизведения контента, так как поддерживает исполнение javascript кода на странице. Таким образом страница будет загружена и динамические элементы будут созданы, после чего можно будет их обработать. Однако на некоторых веб-сайтах для того, чтобы получить ту или иную информацию необходимо заполнить форму. С такими обстоятельствами сложно бороться – разметка всегда различается, но таких случаев крайне мало, поэтому исключение их из рассмотрения будет оправданным.

Проблема 6 может отчасти решиться конкретизацией поискового запроса путем прибавления к названию производителя ключевых слов и про-

дукции, которая им производится. Хотя этот вариант и показал гораздо более качественные результаты нежели чем поиск производителя «как есть», иногда все же присутствует шум.

2.7 Приложение веб-скрейпер

2.7.1 Первичная декомпозиция и планирование

Начальным этапом решения задачи является первичная декомпозиция, в ее результате выделяются подзадачи различной важности, которые должны быть решены для доведения цикла разработки до конца. В данном случае можно выделить следующие подзадачи:

- 1) определение источника информации о различной IoT-продукции,
- 2) отправка поискового запроса,
- 3) получение результатов запроса (список IoT-продуктов),
- 4) определение производителей IoT-продукции,
- 5) поиск официальных сайтов производителей в сети интернет,
- 6) поиск раздела «политика безопасности» на сайтах производителей,
- 7) скачивание политик безопасности,
- 8) очистка скачанных веб-документов от лишних элементов разметки,
- 9) слияние тегов и оборачивание сырого текста,
- 10) нормализация пунктуации и отступов,
- 11) извлечение текста из тегов.

2.7.2 Структура приложения веб-скрейпера

Исходя из результатов декомпозиции, эффективным подходом выглядит представление приложения в виде последовательно выполняющихся подпрограмм так, что входом модуля является результат работы предыдущего модуля, то есть в виде конвейера. Схема организации приложения представлена на рисунке 16.




Рисунок 16 – Схема организации приложения

Таким образом приложение построено на 4 основных концепциях.

1) Концепция модуля – одна из основополагающих, так как модулем в данном случае выступает любая подпрограмма, участвующая в сборе данных, принимающая входные данные в виде json-файла, и на выходе дающая так же json-файл, чтобы следующий в очереди модуль мог выполнить свою работу. Модули могут быть написаны с нуля, а могут расширять возможности уже существующих посредством механизма наследования. Таким образом можно не переписывая существующий код, а только добавляя новый изменять поведение программы и адаптировать ее под разные задачи сбора данных.

2) Концепция конвейера – этот элемент поочередно вызывает модули и передает данные из одного модуля в другой. В результате отработки всех модулей поэтапно решается поставленная задача, то есть сбор данных из интернет-источников. Конвейер может быть сконфигурирован, в него могут быть помещены любые модули, реализующие соответствующий интерфейс. Также может быть сконфигурирована последовательность запуска модулей сбора данных.

3) Концепция поискового движка – данная концепция порождена в связи с необходимостью сделать приложение как можно более гибким. Такой абстрактный элемент позволяет менять используемые поисковые движки, при-

менять к результатам поиска алгоритмы для определения, какие результаты удовлетворяют условиям поиска, а какие нет.

4) Концепция плагина – плагин обеспечивает сбор данных с какой-либо конкретной торговой площадки. Данная концепция использована так же для обеспечения гибкости приложения – для устранения привязки к конкретным торговым площадкам. Используя механизм наследования, можно переопределить поведение плагина для работы с любой другой торговой площадкой.

Далее была разработана композиционная модель приложения, на ней присутствуют все необходимые для решения задач модули. Схема представлена на рисунке 17.

На рисунке 17 модуль «main» отвечает за запуск программы, развертывание основных ее частей. Там же происходит инициализация пула процессов для параллельного выполнения затратных задач, таких как, например, взаимодействие с «безголовым» браузером. Он так же отвечает за последовательное исполнение подпрограмм – элементов конвейера. Он осуществляет прием выходных и передачу входных данных модулей.

Модуль «initialization» производит проверку файловой системы и создает необходимые директории в папке ресурсов.

Модуль «tools» содержит вспомогательные функции, в частности для ввода и вывода данных в формате json.

Модуль «crawler» отвечает за получение данных с веб-страниц, в нем агрегированы все инструменты для сбора и очистки данных.

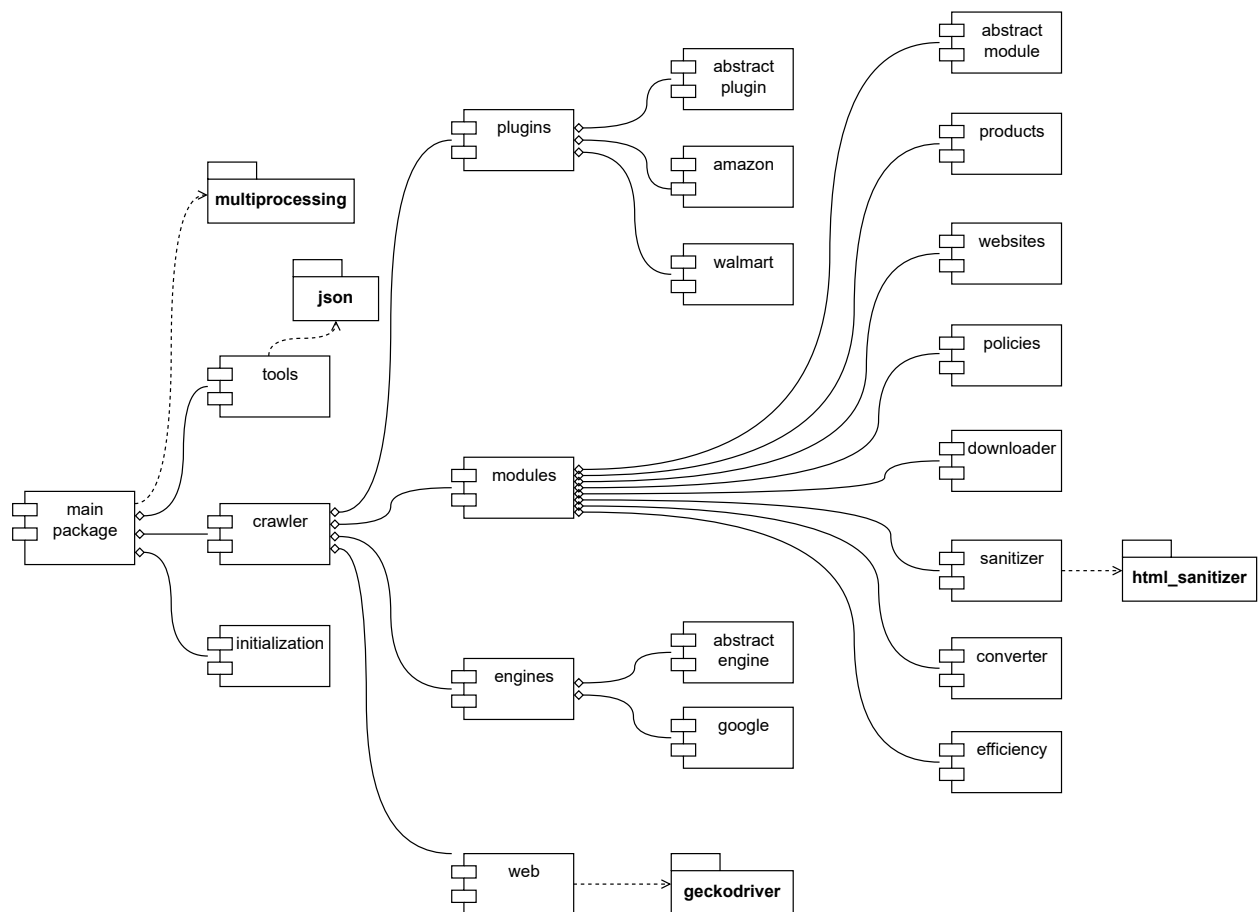


Рисунок 17 – Композиционная модель приложения

Модуль «plugins» включает в себя набор плагинов, каждый из которых адаптирован для получения требуемой информации с определенного шаблона веб-страничной разметки. Некоторое поведение инкапсулировано в абстрактном плагине для увеличения «reusability» кода. Получая адрес на вход, данный плагин производит скачивание страницы и с помощью набора шаблонов пытается извлечь информацию. Данный модуль записывает полученную с помощью плагинов информацию в json-файл для большей прозрачности и возможности сохранения результатов между запусками приложения, например для пропуска данного этапа и использования его сохраненных результатов работы.

Данные, полученные с помощью модулей «products», «websites», «policies», «downloader», «sanitizer», «converter» и «efficiency» записывается в json-файлы для большей прозрачности и возможности сохранения ре-

зультатов между запусками приложения, например при пропуске какого-либо из этапов и использования его сохраненных результатов работы. Модуль «products» отвечает за получение производителей IoT-продуктов. Модуль «websites» отвечает за получение официальных сайтов производителей. Модуль «policies» отвечает за получение веб-ссылок на политики безопасности. Модуль «downloader» отвечает за скачивание страниц и их сохранение в отведенную для этого директорию. Модуль «sanitizer» отвечает за очистку скачанных веб-страниц от ненужных тегов и ссылок. Модуль «converter» производит перевод политик безопасности из веб-страничного вида в текстовое представление. Модуль «efficiency» производит расчет статистики по датасету.

Модуль «web» отвечает за взаимодействие с вебсайтами, будь то торговые площадки или сайты производителей IoT-продуктов. В нем используется geckodriver для управления «безголовым» браузером.

Модуль «проху» содержит инструменты для скачивания и автоматического применения бесплатных прокси-серверов. Однако ввиду ненадежности бесплатных, есть также возможность задать список выделенных прокси-серверов.

Для обеспечения наиболее гибкой настройки, как можно больше настроек выведено в отдельный конфигурационный файл. В нем задаются:

- 1) параметры для библиотеки html-sanitizer, в частности набор допустимых тегов и допустимых атрибутов;
- 2) параметры безголового браузера, в том числе количество повторных попыток при сбоях, появлении captcha и т.д., набор агентов пользователя для перебора, флаги использования кэширования, флаг запуска браузера в режиме без графического интерфейса, флаг использования прокси, пути для логов, а также путь до профиля браузера;
- 3) список директорий и файлов, в которые происходит сохранение ре-

зультатов сбора данных;

4) количество процессов для одновременного сбора данных на много-ядерных конфигурациях.

Для настройки работы заменяемых элементов, таких как поисковые движки, плагины и модули, предусмотрены отдельные файлы, в которых создаются те или иные конфигулируемые объекты.

Учитывая конвейерную организацию и передачу результатов из модуля в модуль посредством json-файлов, структура датасета следующая: каждый модуль имеет свой json-файл для записи результатов. По сути результаты – это массив из python-словарей, каждый словарь является своего рода кортежем, эти кортежи обладают избыточностью данных, однако, таким образом достигается максимальная простота формализации данных. Каждый элемент – IoT устройство, обладающее набором информационных полей: идентификатор; ссылка на страницу на торговой площадке; наименование производителя; ключевое слово, по которому было найдено устройство; ссылка на сайт производителя; ссылка на политику безопасности; путь к сохраненной оригинальной страницы политики безопасности; путь к очищенной политике безопасности; путь к текстовой версии политики безопасности; хэш, сгенерированный по тексту политики; блок статистики по структурным элементам, таким как нумерованные и ненумерованные списки, элементы списков, таблицы, параграфы, длина политики в символах. Пример такой разметки можно увидеть на рисунке 18.

В веб-скрейпере также предусмотрена возможность явного указания адресов для скачивания политик безопасности, для чего выделен отдельный json-файл, содержащий элементы со схожей структурой. В нем можно указывать любые из полей – они будут заполнены соответствующе, а незаполненные поля останутся равными «null». Явно заданные для скачивания политики считываются непосредственно на этапе скачивания, таким образом данные о

названии производителя и другие данные, которые участвуют в более ранних стадиях сбора несут сугубо справочный характер. Статистические показатели политик безопасности рассчитываются на последнем этапе работы приложения, что означает их перезапись после каждого запуска, при условии, что модуль расчета статистики активен.

```
23 {
24   "id": 1,
25   "url": "https://www.walmart.com/ip/
GreaterGoods-Smart-Scale-BT-Connected-Body-Weight-Bathroom-Scale-BMI-Body-Fat-M
uscle-Mass-Water-Weight-FSA-HSA-Approved/696264102",
26   "manufacturer": "greater goods",
27   "keyword": "smart scale",
28   "website": "http://greatergoods.com",
29   "policy": "http://greatergoods.com/legal/privacy-policy",
30   "original_policy":
"D:\\source\\repos\\iot-dataset\\original_policies\\greatergoods.
com-legal-privacy-policy.html",
31   "processed_policy":
"D:\\source\\repos\\iot-dataset\\processed_policies\\greatergoods.
com-legal-privacy-policy.html",
32   "plain_policy": "D:\\source\\repos\\iot-dataset\\plain_policies\\greatergoods.
com-legal-privacy-policy.html.txt",
33   "policy_hash": "9d63c3eeb2a4ef4ad0b4428ad56d4be5",
34   "statistics": {
35     "length": 25888,
36     "table": 0,
37     "ol": 0,
38     "ul": 7,
39     "li": 27,
40     "p": 39,
41     "br": 5
42   }
43 }
```

Рисунок 18 – Пример кортежа датасета

2.7.3 Средства разработки веб-скрейпера

Для реализации приложения были выбраны следующие средства:

- 1) бесплатный текстовый редактор visual studio code,
- 2) система контроля версий git,
- 3) python 3.9,
- 4) «безголовый» браузер Firefox,

- 5) драйвер для управления «безголовым» браузером «geckodriver»,
- 6) библиотека html-sanitizer для очистки скачанных веб-документов.

Выбор «безголового» браузера обусловлен потребностью в отрисовывании страниц, так как на некоторых веб-страницах разметка генерируется с помощью javascript. Это делает невозможным использование простого скачивания, необходима страница именно с исполненными скриптами, в противном случае будет невозможно получить требуемую информацию. В то же время браузер лишен графического интерфейса, чем снижается потребление вычислительных ресурсов.

2.8 Инструмент разметки датасета

Инструмент разметки датасета планируется реализовать с помощью веб-технологий. Серверная часть будет полагаться на приложение, написанное на PHP, которое будет регулировать порядок выдачи текста на аннотирование. Процесс разметки высокодинамичен, поэтому невозможно избежать написания качественной клиентской части приложения на языке javascript. Это позволит сделать работу аннотаторов максимально производительной, в «одну сессию», так как страница не будет перезагружаться. Рассматривая инструмент разметки на высоком уровне абстрагирования, можно отметить несколько основных шагов в работе приложения:

- 1) пользователь получает текст для проведения аннотирования, который передается его клиентской части от сервера;
- 2) пользователь осуществляет аннотирование:
 - пользователь добавляет слои аннотирования к тексту,
 - пользователь убирает слои аннотирования с текста;
- 3) пользователь завершает аннотирование;
- 4) клиентская часть приложения формирует структуру данных, отражающую полученный результат разметки и отправляет ее на сервер;
- 5) серверная часть получает структуру данных и производит ее валидацию с точки зрения соответствия заданной структуре;

б) по завершении валидации, если структура разметки не повреждена, производится ее сохранение в базу данных.

Приложение разделяется на три части, то есть три репозитория:

- репозиторий серверной части приложения,
- репозиторий программы развертывания базы данных,
- репозиторий клиентской части приложения.

2.8.1 Объектное моделирование приложения

Перед непосредственно реализацией инструмента разметки было проведено моделирование на разных уровнях – объектном и реляционном. Объектная модель предметной области представлена на рисунке 19.

В соответствии с полученной реляционной моделью, ключевыми для процесса аннотирования являются 3 сущности:

- «Text» – текст политик безопасности, подлежащих аннотированию,
- «Selection» – Фрагмент пользовательского аннотирования,
- «SelectionClass» – Классификатор фрагмента аннотирования.

Сущность «Text» содержит исходные данные для аннотирования – текст политики безопасности. Пользователь, производя аннотирование политики, выделяет фрагменты текста («Selection») и отмечает их как фрагменты, принадлежащие определенному классу («SelectionClass»). Класс в свою очередь позволяет сформировать дерево классификации разметки, таким образом имея координаты фрагмента в тексте и дерево классификации разметки, возможны эффективный поиск и анализ размеченных текстов политик безопасности.

Сущности «Password», «User Group», «Permission» также являются необходимыми. Они не относятся непосредственно к аннотированию текстов политик, но позволяют идентифицировать аннотаторов и разграничивать доступ к тем или иным функциям инструмента аннотирования.




Рисунок 19 – Объектная модель

2.8.2 Реляционная модель приложения

Далее на основе результатов объектного моделирования предметной области была построена реляционная модель. Реляционная модель предметной области изображена на рисунке 20.

Здесь на рисунке 20 закономерными являются рекуррентные связи в отношениях «SelectionClass» и «Selection», таким образом в реляционной модели обеспечивается построение иерархических структур, в данном случае иерархии разметки текста. В целом, при переходе от объектной модели к реляционной значительных изменений с точки зрения структуры сущностей и связей не потребовалось.




Рисунок 20 – Реляционная модель

2.8.3 Проектирование пользовательского интерфейса

Пользовательский интерфейс инструмента разметки – один из его ключевых компонентов. Аннотирование – сложный, выматывающий процесс, поэтому очень важно, создать комфортные условия для пользователя. Для долгого чтения более предпочтительными являются спокойные темные тона, такие комбинации цветов является наименее раздражительными для зрительных органов. Шрифты для обеспечения совместимости были установлены в соответствии со стандартными, используемыми операционной системой пользователя.

На рисунке 21 синим цветом отмечено выделения пользователя, слева

– инструмент управления слоями разметки, который делает предложение по нанесению какого либо слоя, в рамках заданной иерархии.

На рисунке 22 зеленым цветом отмечен фрагмент разметки, слева – инструмент управления слоями разметки, который предоставляет возможность снять метку с фрагмента текста.

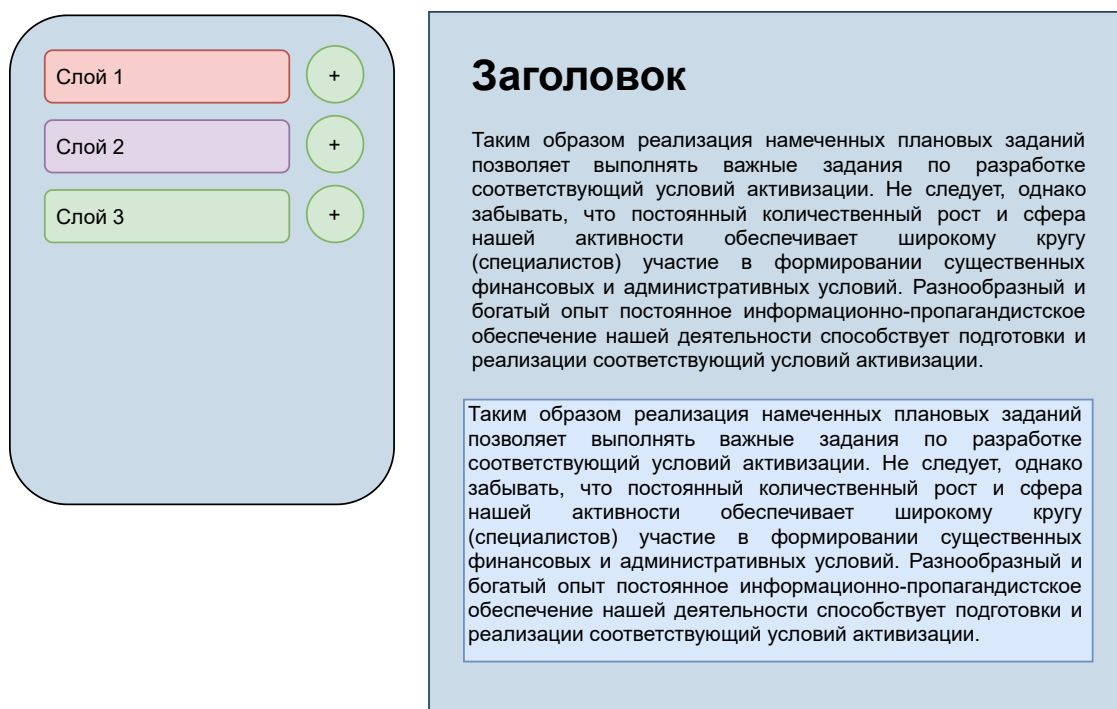


Рисунок 21 – Пример добавления слоев

Презентационный прототип интерфейса инструмента разметки представлен на рисунке 23. Как можно видеть по презентационному прототипу, основная идея заключается в разделении материала на 2 колонки, основная колонка содержит в себе текст политики безопасности, слева – инструмент добавления, просмотра и удаления слоев разметки. Также в приложении предусмотрена глобальная навигация с помощью верхней панели, которая всегда присутствует на экране. В ней же кроме ссылок на страницы приложения присутствует кнопка выхода из учетной записи.

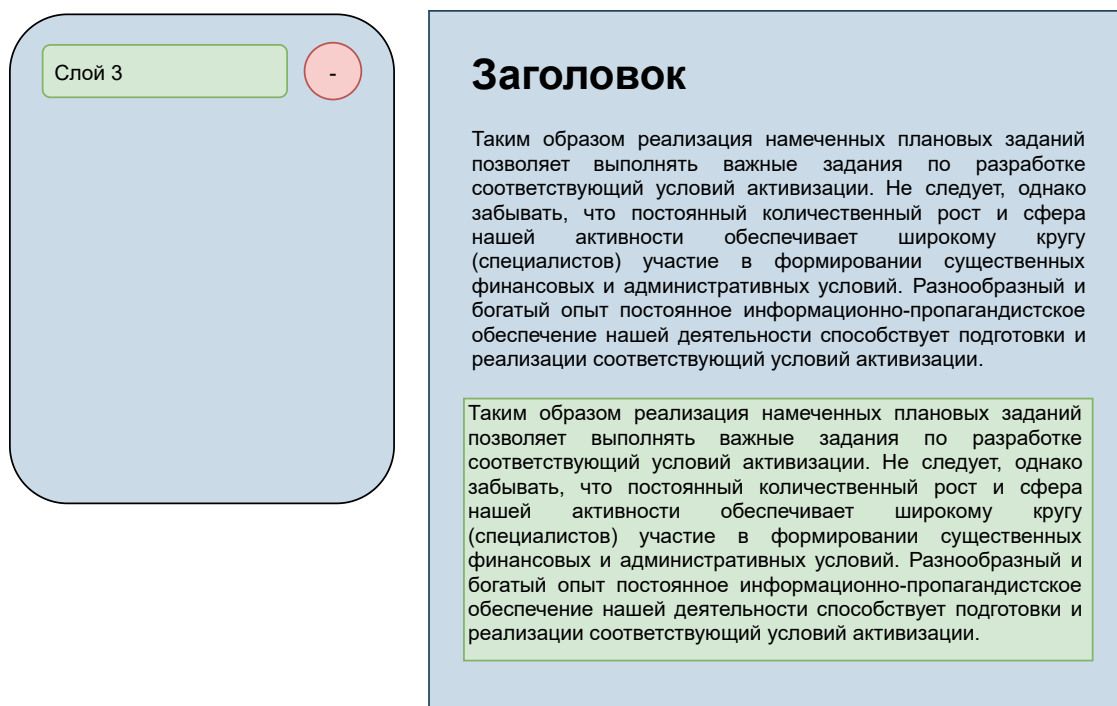


Рисунок 22 – Пример удаления слоя

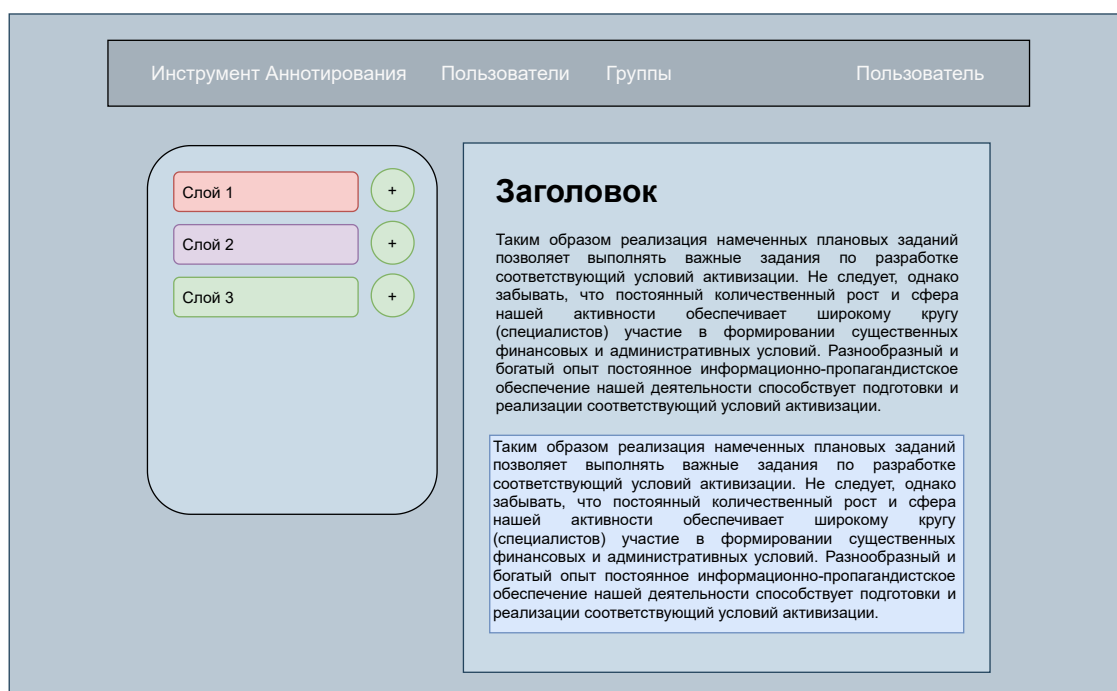


Рисунок 23 – Презентационный прототип интерфейса

В инструменте разметки также предусмотрены функции контроля доступа. В целом, вместе с частью приложения для разметки информационная модель приложения выглядит так, как это показано на рисунке 24.




Рисунок 24 – Информационная модель интерфейса

Результаты разработки пользовательского интерфейса представлены в разделе 3.3.

2.8.4 Диаграммы классов инструмента разметки

Необходимо отметить, что сами по себе построенные в предыдущих разделах модели предметной области не способны функционировать без определенных средств поддержки. Диаграмма классов серверной части приложения приведена на рисунке 25. Для этого было реализовано приложение на основе шаблона проектирования MVC, которое предоставляет пользовательский интерфейс, а также реализует серверную логику инструмента разметки, тем самым связывая все программные части в единую информационную систему.

На диаграмме классов серверной части отчетливо видна область с реализацией слоя моделей паттерна MVC. Они расположились в левой части диаграммы. Над моделями расположены контроллеры, которые отвечают за обработку запросов клиентской части. В правой части расположены многочисленные сервисы – маленькие программные пакеты, решающие конкретные задачи, например переадресация, контроль доступа и т.д. Все сервисы работают внутри специального контейнера, обратившись к которому можно получить доступ к сервисам. Так же приложение включает в себя так называемых посредников. Они обеспечивают последовательную обработку запросов вплоть до отправки ответа клиенту.

Клиентская часть приложения для разметки состоит из трех основных частей: поверхность аннотирования, контейнер слоев разметки и панели управления слоями. Поверхность аннотирования ведет учет выделений текста. Контейнер слоев регистрирует новые слои и удаляет старые по запросу, также он предоставляет информацию о слое по его идентификатору.




Рисунок 25 – Диаграмма классов серверной части приложения

Панель управления слоями предоставляет пользователю возможность добавлять и удалять слои разметки, а также предоставляет информацию о слоях наложенных на те или иные фрагменты текста. Диаграмма классов клиентской части приложения приведена на рисунке 26.




Рисунок 26 – Диаграмма классов клиентской части приложения

2.8.5 Средства разработки инструмента разметки

В качестве среды работы и развертывания инструмента разметки были выбраны следующие инструменты:

- 1) visual studio code – бесплатный текстовый редактор,
- 2) git – система контроля версий,
- 3) nginx – в качестве прокси для обращения к приложению,
- 4) php7.4-fpm – для обработки запросов от nginx и передачи их в приложение,
- 5) mariadb – в качестве СУБД базы данных.

Для реализации инструмента разметки были выбраны следующие средства:

- 1) php 7.4 – как язык написания серверной части приложения,
- 2) composer – пакетный менеджер php,
- 3) javascript стандарта ES6 – для разработки клиентской части приложения,
- 4) webpack – инструмент для сборки клиентской части,
- 5) bootstrap – библиотека для создания пользовательских интерфейсов.

Данный стек технологий был выбран в соответствии с потребностями для разработки инструмента разметки политик безопасности и полностью их удовлетворяет.

2.9 Результаты этапа проектирования инструментария

Подводя итог раздела, посвященного проектированию инструментария для формализации политик безопасности, можно отметить, что вся необходимая подготовительная работа была проведена успешно, были предложены методики для сбора, очистки и разметки текстов политик безопасности. Также было проведено непосредственное проектирование веб-скрейпера и инструмента разметки, включающее в себя рассмотрение потенциальных проблем, которые могут возникнуть на этапе реализации, моделирование программного решения на разных уровнях с применением универсального языка моделирования UML, а также выбор программных средств реализации.

3 Результаты реализации инструментария

3.1 Полученные в результате реализации исходные коды

В соответствии с результатами декомпозиции, выбора средств и проектирования приложение было реализовано. Исходные коды представлены в приложениях А и Б.

3.2 Полученный в результате сбора данных датасет

Поиск IoT-продуктов осуществлялся на торговых площадках Amazon и Walmart, брались результаты поискового запроса по первым 30-ти страницам, по категориям «smart scale», «smart watch», «smart bracelet», «smart lock», «smart bulb», «smart navigation system», «smart alarm clock», «smart thermostat», «smart plug», «smart light switch», «smart tv», «smart speaker», «smart thermometer», «smart air conditioner», «smart video doorbell», «robot vacuum cleaner», «smart air purifier», «gps tracking device», «tracking sensor», «tracking device», «indoor camera», «outdoor camera», «voice controller». Всего производителей было найдено приблизительно 160. Стоит отметить, что результат является приемлемым, так как многие производители на данных торговых площадках не имеют выделенного вебсайта, а пользуются услугами Amazon, то есть на таких страницах действует политика безопасности Amazon, а не производителя. Также стоит отметить, что у некоторых продуктов явно не указан производитель, что количественно сократило результат поиска.

Всего было проанализировано 57150 моделей умной продукции, из них для 51727 (90,5%) были определены производители. Всего уникальных производителей было найдено 6161, из них 1419 (23%) имеют официальную веб-страницу. Проанализировав найденные веб-сайты были собраны 798 политик безопасности, разумеется, среди них имеется определенный процент промахов, если производитель имеет сходство с каким-либо другим более крупным. Из датасета были исключены политики безопасности, длина которых

в символах не превышала 1000. Это объясняется тем, что некоторые производители имеют на своем сайте страницу с политикой безопасности, но по каким-то причинам эта страница не наполнена. Примеры таких случаев приведены на рисунках 27 и 28. Таким образом полноценных уникальных политик безопасности осталось 592.




Рисунок 27 – Пример отсутствующей политики

Некоторые из производителей, которые не имеют собственного веб-сайта и политика безопасности которых не была найдена, пользуются услугами хостинга интернет-магазина непосредственно на Amazon. В таком случае,

будучи частью интернет-магазина на них распространяется политика безопасности площадки, на которой они размещают свои предложения, причем политики могут различаться для разных стран.

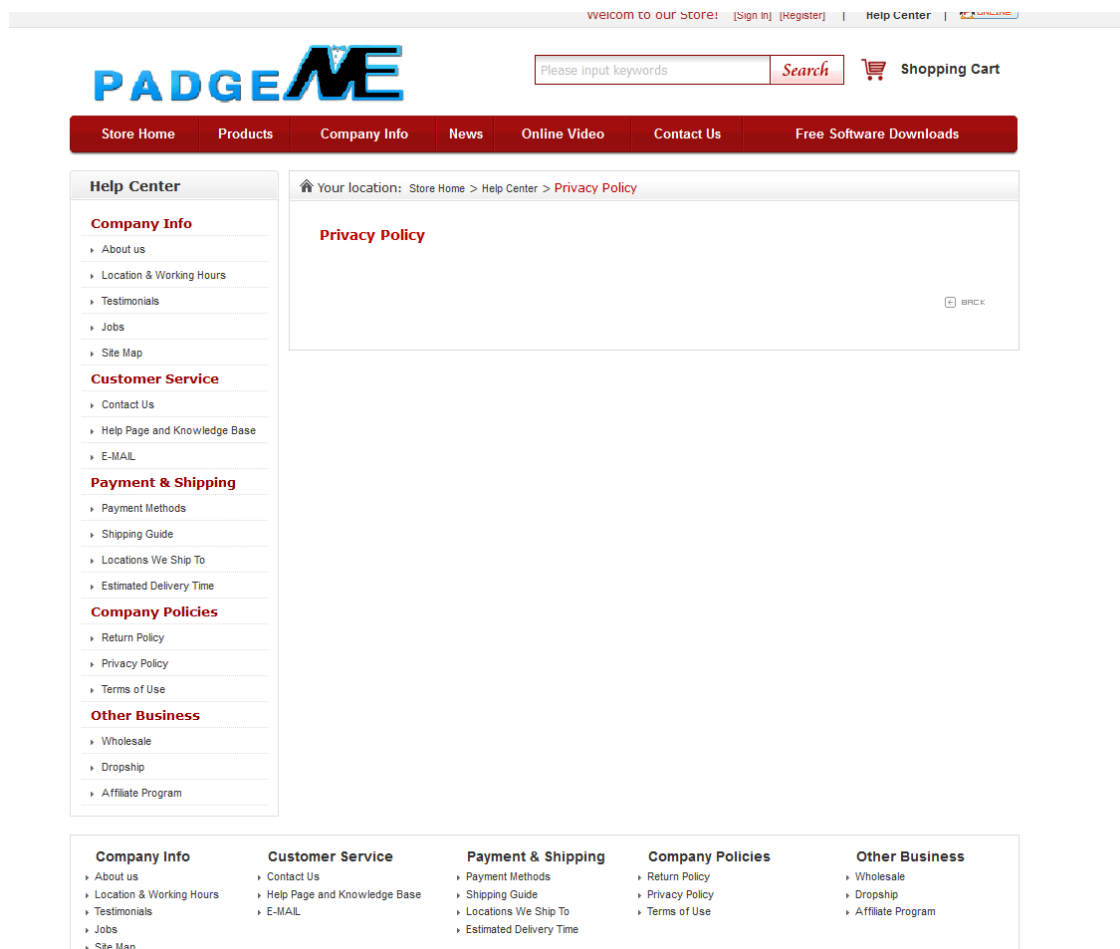


Рисунок 28 – Пример отсутствующей политики

Случаи с использованием отдельных политик безопасности под различные типы устройств не были зафиксированы, хотя такие случаи и существуют, проще прибегнуть к явному заданию адресов политик, нежели чем к попытке автоматизировать процесс сбора, так как остаются непрозрачными способы выявления подобных ситуаций.

На рисунках 29 и 30 приведены статистические данные по объемам абзацев политик и самих документов соответственно.




Рисунок 29 – Распределение политик по объему параграфа




Рисунок 30 – Распределение политик по объему документа

Подсчет количества заголовков сложно организовать автоматизированно в связи с большим разнообразием html-разметки. На каждом сайте своя разметка, своя конвенция по нумерованию секций, заголовков, списков. На некоторых сайтах списки и заголовки нумеруются средствами html, на других нумерация проставлена вручную. Все это порождает разношерстность данных, и их обработка становится сложной с точки зрения учета всех возможных вариантов. Поэтому авторы решили прибегнуть к простому подсчету длин строк длиной меньше 100 символов и не содержащих при этом маркеров «list item». Такой подход не даст очень точных показателей, но может дать приблизительные значения. На рисунках 31 и 32 приведена статистика по структурным элементам политик безопасности в двух частях. Здесь изображены детальные распределения структурных элементов для каждой из найденных политик безопасности.




Рисунок 31 – Статистика первых 246 политик в IoT-датасете по структурным элементам




Рисунок 32 – Статистика последних 246 политик в IoT-датасете по структурным элементам

Таким образом можно описать среднестатистическую политику безопасности, которая состоит из 31.5 абзацев, 33 заголовков, 23.6 элементов перечислений, 0.7 нумерованных списков, 4.4 нenumерованных списка, 0.5 таблиц.

Для дополнительного статистического анализа датасета, он был кластеризован с помощью латентного размещения Дирихле. Как и в предыдущих разделах для кластеризации политики безопасности были разбиты на абзацы, после чего была проведена предобработка, состоящая из лемматизации, удаления пунктуации и так называемых стоп-слов. В таблице 10 приведены результаты моделирования тем в IoT-датасете. В предыдущих разделах уже была исследована точность латентного размещения Дирихле, его преимущества и недостатки, на основании чего IoT-датасет был проанализирован именно таким способом. По результатам видно, что с помощью такой кластеризации можно выделить различные аспекты политик безопасности.

Таблица 10 – Тематическое моделирование

№	Координаты семантического пространства	Возможные сценарии использования
0	email, send, promotional, communication, marketing, opt, product, service, message, list	First-party collection, Opt-in, opt-out messages and notifications to end user
1	party, third, service, information, privacy, website, share, policy, site, advertising	Third parties sharing for marketing purposes
2	removed, href, hyperref, question, contact, privacy, us, please, policy, comment	Contact information: company
3	cookie, device, browser, service, address, website, site, collect, information, use	First-party collection: browser and device information
4	child, age, entering, detection, year, fill, redirected, show, knowingly	Special audience: children
5	sensor, educational, suggestion, top, acquirer, mailing, employment, job, taking, clickstream	First-party collection: device and service specific information
6	corporate, automated, storefrontdigest, indefinite, personalization, direction, administrator, token, shop, employed	Other
7	data, personal, right, request, processing, information, necessary, legal, purpose, law	First-party collection: right to edit, access, with specified (legal) basis of data processing
8	sponsor, push, reply, default, swiss, desire, becoming, correspondence, calling, representative	Other
9	asset, service, product, merger, company, item, list, business, another, referral	Third-party sharing in case of company acquisition and merging
10	erasure, unaffiliated, input, approximate, format, appliance, pref, persistent, canadian, short	Right to erase
11	address, name, information, account, email, promotion, password, u, collect, contact	First-party collection: personal and account information
12	security, protect, safety, hosted, secure, violate, property, others, technical, law	Data security
13	california, state, resident, institution, law, united, ccpa, right, request, country	Special audience: California residents
14	change, policy, privacy, statement, time, notice, pci, payment, ds, update	Privacy policy changes

При кластеризации порог аффилиации абзаца политики безопасности был установлен в 0.3, параграф относился к нескольким кластерам, если вероятность аффилиации с ним была больше указанного порога. По графику на рисунке 33 можно судить, какую часть от общего объема текстов занимают те или иные аспекты политик безопасности.




Рисунок 33 – Статистика аспектов в IoT-датасете

Как заключение статистического обзора сформированного датасета на рисунках 34 и 35 приведено детальное распределение аспектов политик безопасности по каждой конкретной политике.




Рисунок 34 – Статистика первых 246 политик в IoT-датасете по аспектам




Рисунок 35 – Статистика последних 246 политик в IoT-датасете по аспектам

Здесь в виде гистограммы представлены распределения всех 15 аспектов, выделенных алгоритмом LDA. Каждый абзац может относиться к нескольким аспектам с порогом аффилиации 0.3.

3.3 Полученный в результате реализации инструмент разметки

В ходе реализации был разработан инструмент разметки датасета. На рисунках 36–41 представлен его конечный вид. В качестве тестового примера была взята часть онтологии, предложенной в [15], и посвященной описанию активности по отношению к персональным данным. Инструмент был настроен для работы с указанной частью онтологии. Выделения и нанесенная разметка в данных примерах не являются осмысленными и выполнялись исключительно с целью демонстрации работоспособности приложения.

На рисунке 36 представлено начальное состояние страницы разметки. В начальном состоянии панель инструментов не показывает ни одного слоя, текст для разметки представлен в первоначальном виде.

На рисунке 37 представлена реакция инструмента на выделение текста пользователем. При выделении пользователем текста на панели слоев за-

крепятся слои доступные для наложения, выбранные контекстуально, в соответствии с настроенной иерархией разметки.

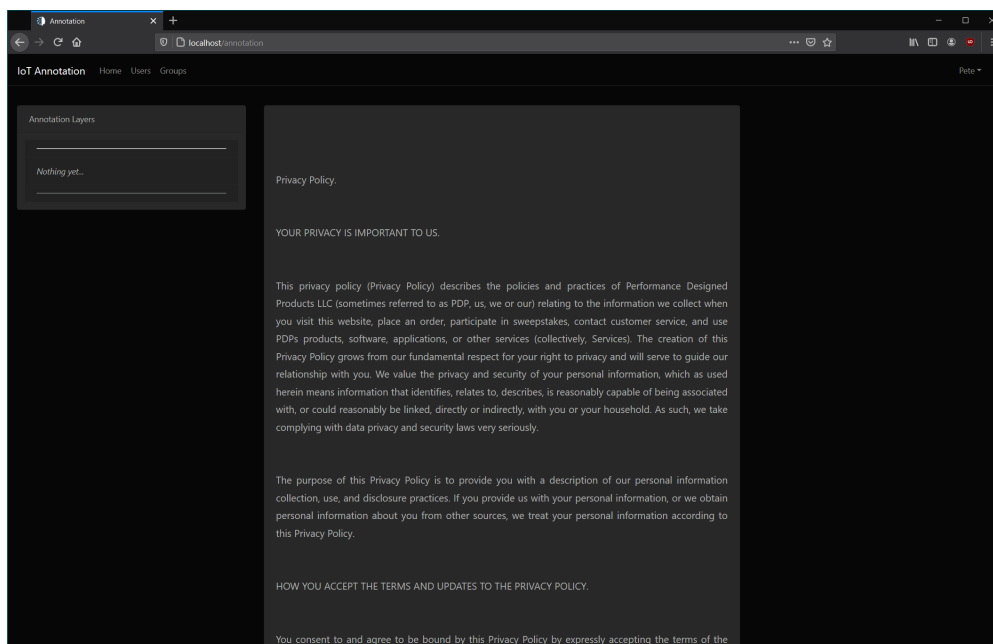


Рисунок 36 – Начальное состояние страницы разметки

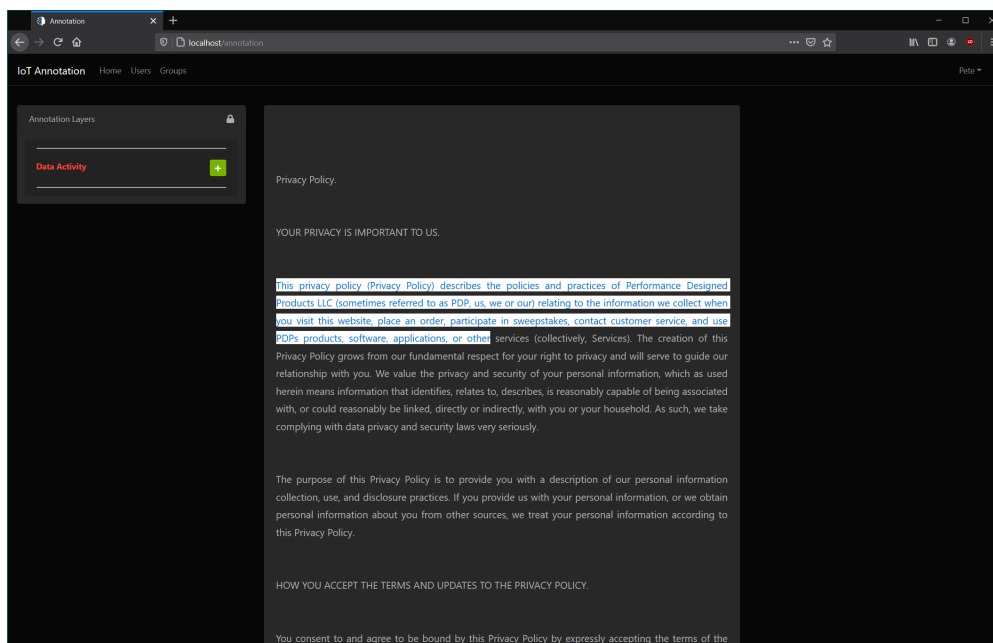


Рисунок 37 – Выделение текста

На рисунке 38 представлено состояние страницы разметки после нанесения слоя разметки. Теперь панель слоев отображает текущие наложенные слои для элемента, на который наведен указатель мыши.

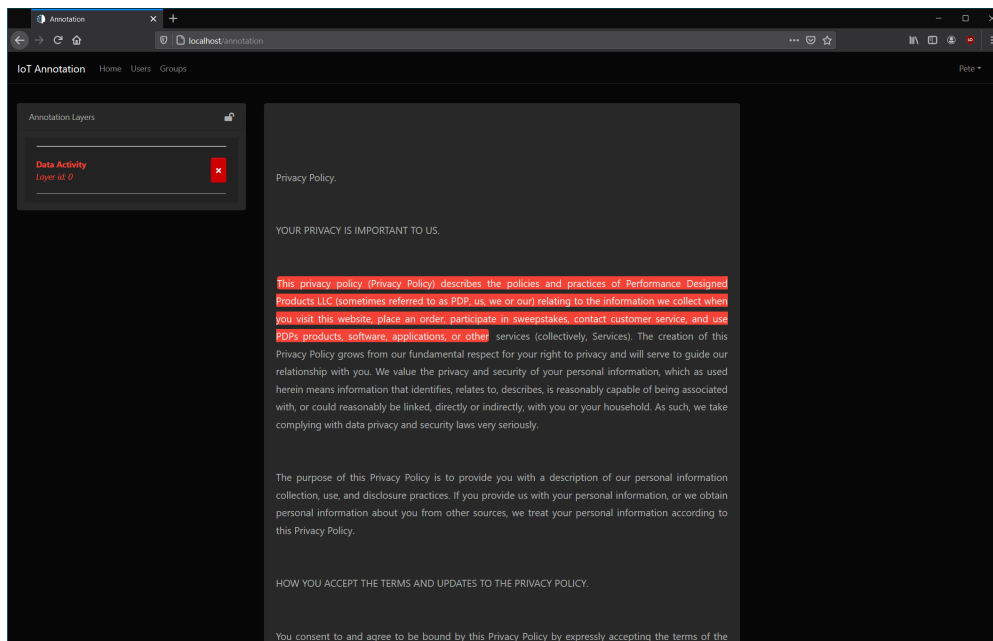


Рисунок 38 – Нанесение слоя разметки

На рисунке 39 представлена реакция инструмента на выделение текста пользователем. Теперь контекстуально на основе информации о наложенных слоях, предлагаются слои другого уровня детализации.

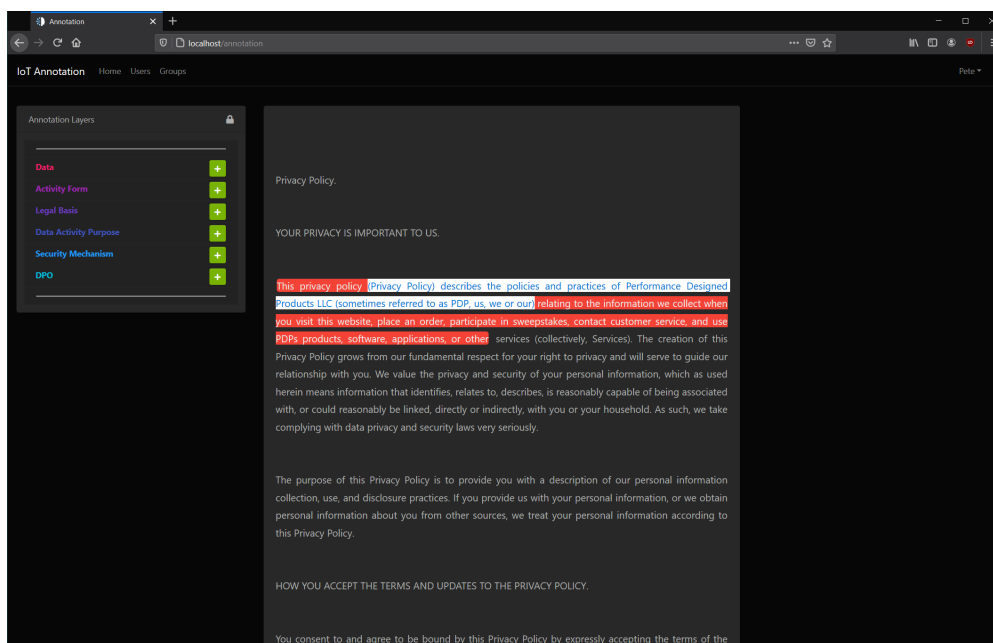


Рисунок 39 – Выделение размеченного текста

На рисунке 40 представлено состояние страницы разметки после нанесения нескольких неконфликтующих слоев разметки.

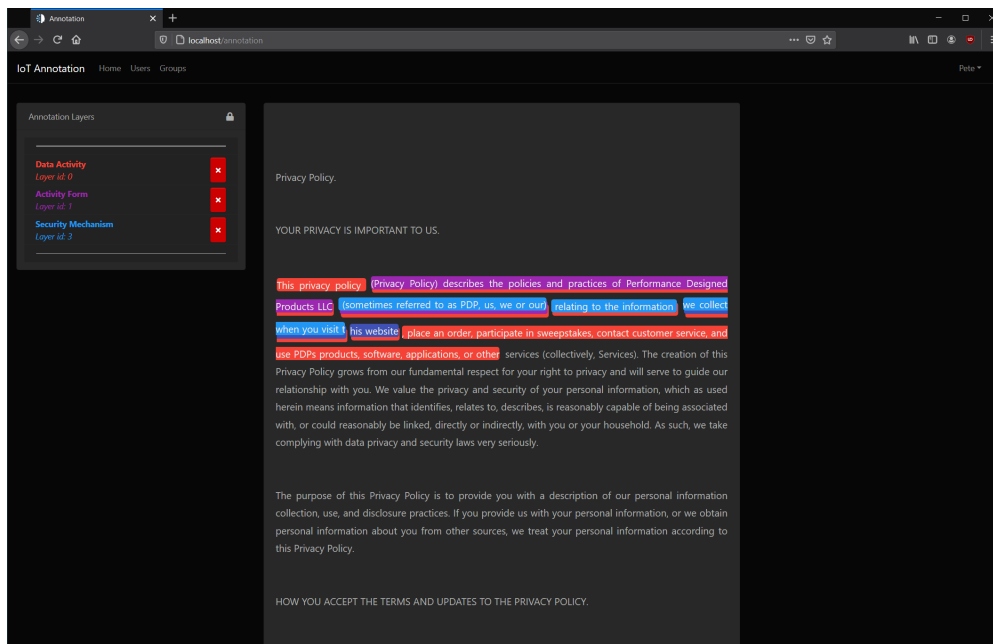


Рисунок 40 – Нанесение нескольких слоев

На рисунке 41 представлено состояние страницы разметки после удаления одного из слоев разметки. Поверхность аннотирования осуществляет поиск одинаковых по составу слоев разметки и производит их слияние, так что фрагменты с одинаковым набором слоев выглядят целостно.

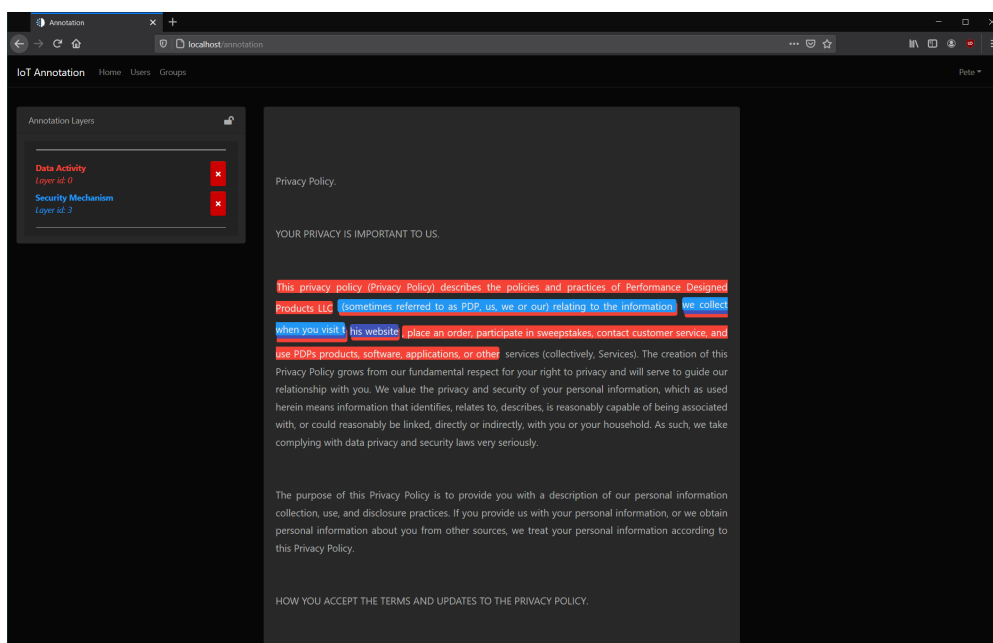


Рисунок 41 – Удаление слоя

3.4 Итоги этапа реализации

Подводя итоги раздела, посвященного реализации инструментария для формализации политик безопасности, можно отметить, что на данном этапе были успешно получены программные коды всех компонентов инструментария. С помощью разработанного веб-скрейпера с модульной архитектурой был произведен сбор политик безопасности из открытых источников, а именно 592 политики безопасности производителей IoT-устройств. Были подробно рассмотрены статистические и структурные особенности политик безопасности. Полученный датасет имеет ряд преимуществ по сравнению с существующими датасетами, например из работы [18], так как он был сформирован в 2021 году, после принятия GDPR в качестве основного международного документа по защите персональных данных. Также датасет является одним из немногих по его тематической ориентации на IoT-устройства. В соответствии с планом по реализации был разработан инструмент разметки текстов политик безопасности для построения обучающей выборки, результат его работы был также представлен.

4 Составление бизнес-плана по коммерциализации результатов научно-исследовательской работы магистра

4.1 Описание концепции проекта

4.1.1 Название проекта

В течение работы над научно-исследовательской работой магистра, не было выбрано названия для проекта, исходя из предназначения программного пакета и ориентации на мультиязычную аудиторию стоит выбрать максимально понятное название, возможными вариантами являются:

- 1) Machine Learning Annotation ToolKit
- 2) Dataset Mining ToolKit

4.1.2 Сущность проекта

В сущности программный пакет представляет из себя набор программ для решения задач по автоматизированному сбору датасетов с их последующей разметкой при помощи инструмента аннотирования, который так же входит в состав данного пакета.

Бизнес-ситуация на данный момент характеризуется следующими особенностями:

- 1) инструментариев для сбора датасетов практически не найти;
- 2) инструменты аннотирования, которые существуют, не обладают необходимым функционалом.

4.1.3 Реальная бизнес-ситуация, служащая обоснованием проекта

Задача выпускной квалификационной работы, поставленная в разделе 1, является актуальной и заслуживает внимания. Данные особенности не позволяют решить задачи, имеющиеся в предметной области выпускной квалификационной работы, на базе существующих решений (образование незанятой рыночной ниши), что автоматически означает необходимость в разработке новых решений.

4.1.4 Цели проекта

Целью проекта является реализация инструментария для сбора и аннотирования датасетов, соответствующего техническому заданию и требованиям методик, разработанных для решения задач предметной области. Стоит отметить, что проект разрабатывается не сугубо под задачи представленные в разделе 1, разработанный инструментарий будет способен решать целый класс задач, а именно автоматизированный сбор датасетов из сети Интернет с их последующим аннотированием.

4.1.5 Границы проекта

Проект не включает в себя разработку инструментов для работы с технологиями машинного обучения, на сегодняшний день подобные инструменты представлены на рынке достаточно широко. Также проект не включает в себя проведение аннотирования, так как для этого необходимы эксперты из разных предметных областей (так как инструмент решает целый класс задач сбора и аннотирования датасетов), достаточно компетентные, чтобы создать качественную обучающую выборку для моделей, основанных на технологиях машинного обучения. Обучение моделей, основанных на глубоком обучении, так же не будет производиться, данный шаг будет выполняться отдельно каждым потребителем, который к тому же выберет необходимые для решения своей задачи технологии. Таким образом в проект входит только программное обеспечение – веб-скрейпер и инструмент аннотирования.

4.1.6 Допущения

При нынешнем состоянии предметной области, а именно активном продвижении методик формализации данных, остается нерешенным вопрос формирования обучающих выборок для моделей глубокого обучения. На данный момент исследователи и специалисты в этой области вынуждены под каждую конкретную задачу разрабатывать свой собственный инструмент. Таким образом проект имеет смысл реализовывать при текущем состоянии

рынка.

4.1.7 Заинтересованные стороны проекта

Потенциальными заинтересованным сторонами проекта являются исследователи, специалисты, энтузиасты, коммерческие организации и некоммерческие организации, работающие в области машинного обучения. Проект создается для удовлетворения их потребностей в инструментах формирования и аннотирования наборов данных для обучения соответствующих моделей. Проект является значимым, потому что он позволит заинтересованным сторонам отойти от разработки инструментов сбора и аннотирования под каждую конкретную задачу, и позволит им, экономя временные, денежные и трудовые ресурсы, заниматься задачами, в которых действительно необходима их компетенция.

4.1.8 Риски проекта

К рискам проекта можно отнести некоторую конкуренцию по части инструментов аннотирования, так как имеются некоммерческие разработки под свободными лицензиями. Заинтересованные стороны при ограниченных ресурсах все же могут обращаться к таким разработкам, хотя они не являются продуктами уровня коммерческого производства и зачастую обладают серьезными недостатками.

4.1.9 Ориентировочные сроки проекта

Ориентировочно проект планируется реализовать за 6 календарных месяцев – это основной цикл разработки. После осуществляется переход на цикл поддержки продукта, предоставлении сервисных услуг, связанных с обслуживанием программного обеспечения и консультациями, планомерная доработка продукта с точки зрения нового функционала.

4.1.10 Первоначальная организация проекта

В деятельности организации будут участвовать отделы:

- 1) HR-служба,
- 2) отдел системного администрирования,

- 3) отдел разработки,
- 4) отдел поддержки,
- 5) бухгалтерия.

4.1.11 Ориентировочный бюджет проекта

Ориентировочный бюджет проекта на первые 6 месяцев активной фазы разработки 6 000 000 рублей, сюда будут входить затраты на заработную плату, страховые отчисления, аренду помещений, электроэнергию и коммунальные услуги.

4.2 Описание продукции

Описание продукции приведено в таблице 11.

Таблица 11 – Описание продукции

Ключевые вопросы	Комментарии
Наименование продукции	Программный комплекс в соответствии с ГОСТ 19.101-77
Назначение продукта	Автоматизированный сбор данных из открытых источников, аннотирование обучающих выборок для моделей машинного обучения
Основные характеристики продукта	Продукт по части автоматизированного сбора данных занимает фактически пустующую нишу, включает важные функции по обходу блокировок и многопроцессному исполнению; по части аннотирования предлагает новый функционал по сравнению с имеющимися конкурентами. Продукция находится на стадии опытно-конструкторских работ
Потребительские свойства продукции	С помощью продукта потребитель затрачивает гораздо меньше времени на разработку инструментов под свои задачи, таким образом расходует больше ресурсов на решаемую им задачу, а не на сбор данных
Основные конкурентные преимущества продукции	Настраиваемая среда сбора данных из открытых источников, конфигурируемое аннотирование с возможностью иерархической пересекающейся разметки. Обход блокировок на сайтах и многопроцессное выполнение
Основные потребители и направления использования продукции	Исследователи, специалисты, энтузиасты, коммерческие организации и некоммерческие организации, работающие в области машинного обучения
Ассортимент и структура выпуска продукции	Предполагается совместная поставка веб-скрейпера и инструмента аннотирования
Юридическая защищенность продукции	Лицензия

Продолжение таблицы 11

Ключевые вопросы	Комментарии
Дополнительные сервисные услуги	Поддержка и консультирование пользователей; стоимость данных услуг включается в стоимость подписки

4.3 Анализ рынка сбыта продукции

4.3.1 Положение дел в отрасли

Отрасль IT и машинного обучения в частности является стремительно развивающейся. Тенденции роста данной отрасли продолжатся и в перспективе, так как машинное обучение позволяет решать множество прикладных задач. В 2020 году объем инвестиций в разработки на основе технологий искусственного интеллекта вырос на 40%, достигнув \$67,9 млрд. Об этом свидетельствуют данные из отчета AI Index Report 2021 от исследователей Стэнфордского университета. Данная отрасль имеет огромное значение для бизнеса, социального и экономического развития, о чем и свидетельствует статистика по объемам инвестиций. Техническая оснащенность отрасли находится на высочайшем уровне из-за потребности в сложных вычислениях. Однако, помимо коммерческой основы проводятся и некоммерческие исследования, их наличие тоже следует учитывать.

4.3.2 Характеристика внешней среды проекта

PEST-анализ приведен в таблице 12.

Таблица 12 – PEST-анализ

Область	Фактор	Состояние	Характер влияния
Политическая	Санкции	Затрудняется взаимодействие с иностранными клиентами и провайдерами услуг	Отрицательное
Экономическая	Рост отрасли	Отрасль привлекает большое количество инвестиций	Положительное
Социальная	Рост отрасли	Отрасль привлекает большое количество специалистов	Положительное

Продолжение таблицы 12

Область	Фактор	Состояние	Характер влияния
	Большое количество кадров на рынке в связи с эпидемиологической обстановкой	В связи с эпидемиологической обстановкой большое количество кадров было сокращено, специалисты стали чаще обращать внимание на предложения работы в удаленном формате, появилась возможность искать кадры без географической привязки	Положительное
	Удаленный формат занятости из-за эпидемиологической обстановки	Затрудняется коммуникация среди сотрудников, влияние на работоспособность	Отрицательное
	Количество квалифицированных кадров	С каждым годом увеличивается количество специалистов в сфере IT, растет количество образовательных мест по IT направлениям	Положительное
Технологическая	Вклад технологии машинного обучения в развитие рынка	За последние годы количество инвестиций в технологии машинного обучения стабильно растет, и продолжит свой рост	Положительное
	Широта приложения технологий машинного обучения	Обеспечивает востребованность проекта в различных предметных областях, где используется машинное обучение	Положительное

SWOT-анализ приведен в таблице 13.

Таблица 13 – SWOT-анализ

Сильные стороны	Слабые стороны
<ul style="list-style-type: none"> – Наличие опции автоматизированного сбора информации, – наличие поддержки пересечения разметки, – наличие поддержки иерархий разметки, – загрузка текстовых корпусов целиком, – поддержка и консультирование клиентов 	<ul style="list-style-type: none"> – Платная основа, – нахождение проекта с стадии опытно-конструкторских работ

Продолжение таблицы 13

Возможности	Угрозы
<ul style="list-style-type: none"> – Наличие опции автоматизированного сбора информации, – обход блокировок и captcha, – наличие поддержки пересечения разметки, – осуществление аннотирования обучающих выборок, – наличие поддержки иерархий разметки, – загрузка текстовых корпусов целиком 	<ul style="list-style-type: none"> – Нежелание потенциального заказчика платить за продукт, – эпидемиологическая обстановка

4.3.3 Анализ рынка

Исходя из роста инвестиций в технологии машинного обучения, спрос на продукцию связанную с такими технологиями неуклонно растет. Специалистам в данной области требуются инструменты, сокращающие затраты на разработку вспомогательных программ добычи данных, а также разметки обучающих выборок. Используя готовые решения, специалисты занимаются непосредственно своей основной работой, решают поставленные задачи в кратчайшие сроки, что позволяет производству прогрессировать и расти быстрее. Барьером для удовлетворения потребности можно считать сложность создания гибких инструментов для решения обозначенных ранее задач.

Факторы влияющие на выбор продукта:

- 1) функциональная оснащенность,
- 2) стоимость программного продукта,
- 3) предоставляемая поддержка и консультирование,
- 4) качество программного продукта.

Потенциальные потребители коммерческие и некоммерческие организации (штатные специалисты и исследователи), а также свободные специалисты и исследователи. Специалисты и исследователи постоянно ищут новые подходы к решению задач, и потому следят за профессиональной литературой и публикациями.

4.3.4 Сегментирование рынка и выбор целевых сегментов

Далее рассматривается сегментирование рынка. Категории потенциальных пользователей, заинтересованных в инструментарии:

- сегментирование по географическому принципу – приложение будет распространяться не только на территории России, но и других стран, однако стоит отметить, что инструментарий будет переведен только на английский язык;

- психографическое сегментирование – инструментарий может использоваться людьми разных социальных классов, ведущих любой образ жизни;

- поло-возрастное сегментирование – инструментарий может использоваться людьми вне зависимости от их пола и возраста;

- демографическое сегментирование рынка – преимущественно потребителями являются свободные и штатные специалисты в области машинного обучения, обладающие высокими доходами, также потребителями могут быть студенты, для пользования требуется определенный уровень компетенции в области машинного обучения.

В связи указанными сегментами планируется использовать модель распространения инструментария по подписке. Таким образом для охвата всех указанных сегментов будет использована следующая политика распространения:

- свободные специалисты оплачивают подписку для физического лица;
- студенты, подтвердившие свой статус, получают льготы на оформление подписки для физического лица;
- корпоративные клиенты оплачивают подписку для юридических лиц.

4.4 Анализ конкурентов

Анализ конкурентов приведен в таблице 14.

Таблица 14 – Анализ конкурентов

Название конкурента/конкурирующего проекта	Пересечение разметки	Иерархическая разметка	Платная основа	Наличие инструмента сбора информации	Загрузка текстовых корпусов целиком
Dataset Mining ToolKit	+	+	+	+	+
Inception	–	+	–	–	+
Doccano	–	–	–	–	+
Label Studio	–	+	–	–	+

Конкуренция скорее является неценовой, она основывается на предоставляемом в продукте функционале.

Отсутствие таких функциональных возможностей как пересечение разметки и иерархическая разметка могут пагубно сказаться на качестве и детализации обучающих выборок, а от обучающей выборки напрямую зависит результат работы моделей машинного обучения.

Исходя из представленных данных, можно заключить, что предлагаемая продукция по ряду критериев превосходит конкурентов в своей области. Однако, платная основа распространения может рассматриваться потребителями как недостаток.

4.5 План маркетинга

4.5.1 Товарная политика

Основными функциональными свойствами продукта являются: осуществление автоматизированного сбора информации, многопроцессный режим, обход блокировок и captcha, наличие поддержки пересечения разметки, осуществление аннотирования обучающих выборок, наличие поддержки иерархий разметки, загрузка текстовых корпусов целиком.

Разрабатываемый инструментарий обладает определенными техническими требованиями:

– веб-скрейпер:

- 1) предустановленный браузер Firefox;
 - 2) наличие интерпретатора python 3.9;
- инструмент аннотирования:

- 1) предустановленный веб-сервер;
- 2) предустановленная СУБД;

Предлагаемый инструментарий планируется сбывать по разным тарифам (образуя таким образом ассортимент), то есть будет сделан шаг навстречу потребителям, который позволит им оплачивать подписку на продукт в соответствии с их финансовыми возможностями.

Программный продукт будет поставляться в виде цифровой копии, безопасность и защита от хищения будет осуществляться на основе лицензионных ключей.

В качестве дополнительных услуг (включенных в стоимость подписки) будут предоставляться сервисные услуги по настройке и внедрению продукта. Также будут предоставляться услуги по консультированию (также включенных в стоимость подписки).

4.5.2 Распределительная политика

География сбыта не привязана к конкретным территориям и регионам, сбыт планируется посредством оформления подписки через интернет сервисы. Таким образом предпочтительным выбран прямой канал сбыта продукции. Так как продукция поставляется в виде электронной копии, доставка не предусматривается.

4.5.3 Коммуникационная политика

Целевая аудитория совпадает с целевыми сегментами. Инструментами продвижения продукции могут послужить посты в тематических группах в социальных сетях и на форумах, таким образом планируется охватить аудиторию свободных специалистов и студентов. Также важными являются каналы коммуникации через публикации в журналах, выставки и конференции, таким образом планируется охватить аудиторию занятых специалистов, ком-

мерческие и некоммерческие организации. Также большой успех может принести практикум, размещенный на одном из видеохостингов, который сможет продемонстрировать все возможности программного продукта и в то же время помочь начинающим с его освоением. Указанные каналы продвижения находятся максимально близко к целевой аудитории, поэтому были выбраны именно они. Описание коммуникационной политики приведено в таблице 15. Расчет бюджета продвижения и график продвижения представлены в таблицах 16 и 17 соответственно.

Основная концепция товара – облегчение труда для специалистов, работающих в сфере машинного обучения, соответственно реклама должна отражать данный факт, так же в рекламе стоит указать о достоинствах продукта по сравнению с конкурентами.

Таблица 15 – Концепции и инструменты продвижения

Инструмент	Канал	Концепция
Реклама	Реклама в журнале Computer World	Описание концепции, почему данный инструмент необходим специалистам области
	Практикум на YouTube	В практикуме показываются преимущества программного продукта, знакомство новых пользователей с ним, помощь новичкам в освоении
Связи с общественностью	Обзорные статьи в научном журнале CyberLeninka	Описание хода разработки, подходов к решению задач
Интернет-представительство	Веб-страница продукта	Одностраничный сайт, для демонстрации возможностей, технических характеристик

Таблица 16 – Расчет бюджета продвижения

Инструмент	Наименование мероприятия	Период мероприятия	Место размещения	Расчет затрат	Итого сумма
Реклама	Реклама в журнале Computer World	01.09.2021 - 07.09.2021	Электронный журнал	Размещение рекламы в конце журнала	285 560 руб.

Продолжение таблицы 16

Инструмент	Наименование мероприятия	Период мероприятия	Место размещения	Расчет затрат	Итого сумма
	Практикум на YouTube	08.09.2021 - 15.09.2021	Видеохостинг YouTube	Съемка (50000 руб.) + монтаж (20000 руб.)	70 000 руб.
Связи с общественностью	Подготовка публикации в CyberLeninka	01.01.2022 - 07.01.2022	Электронный научный журнал	Услуги редактора	20 000 руб.
	Подготовка публикации в CyberLeninka	01.01.2023 - 07.01.2023	Электронный научный журнал	Услуги редактора	20 000 руб.
Интернет-представительство	Одностраничное веб-приложение	01.09.2021 - 24.09.2021	сеть Интернет	Разработка веб-приложения	149 800 руб.
Итого на продвижение					545 360 руб.

Таблица 17 – График продвижения

Мероприятие	Кварталы											
	I	II	III	IV	I	II	III	IV	I	II	III	IV
Реклама в журнале Computer World				×								
Практикум на YouTube			×	×	×	×	×	×	×	×	×	×
Подготовка публикации в CyberLeninka					×				×			
Одностраничное веб-приложение			×	×	×	×	×	×	×	×	×	×

4.5.4 Ценовая политика

Стратегия ценообразования учитывает разные сегменты рынка. Так разным потребителям будут поставляться одни и те же продукты, но по разным ценам. Цены для организаций будут значительно выше, чем для свободных специалистов исследователей и студентов. Студенты получают льготы – снижение стоимости подписки на программный продукт. Подписка на продукт оформляется на 3 месяца.

Цены на продукцию высчитываются из срока окупаемости, так как продукт не требует производства для продажи, он разрабатывается один раз и затем сбывается потребителям в виде копий.

4.5.5 План продаж

План продаж рассчитанный на 3 года представлен в таблицах 18, 19 и 20. Здесь «п. физ.» – подписка для физических лиц, «п. юр.» – подписка для юридических лиц, «п. ст.» – подписка для студентов. В начале ожидается быстрый рост продаж в связи с продвижением продукта, соответственно в кварталах, где проводилось продвижение ожидается рост сбыта. При этом определенное количество потребителей будут отказываться от продукта. Те потребители, которые будут довольны продуктом, будут продлевать подписку. Подобное продвижение будет сделано и спустя год после выхода продукта на рынок, чтобы поддерживать количество потребителей. Плановая доработка продукта отделом разработки будет так же удерживать определенное количество клиентов. В первом и втором кварталах каждого года предположительно будет происходить рост сбыта льготных подписок студентам, в связи с выполнением курсовых и дипломных работ.

Таблица 18 – План продаж, год 1

Показатели	Кварталы				Всего
	I	II	III	IV	
Ожидаемый объем продаж, ед.	–	–	2000 п. физ. 50 п. юр. 1900 п. ст.	2500 п. физ. 75 п. юр. 1200 п. ст.	5500 п. физ. 125 п. юр. 3100 п. ст.
Цена с НДС, тыс. руб.	–	–	1,250 п. физ. 62,5 п. юр. 0,625 п. ст.	1,250 п. физ. 62,5 п. юр. 0,625 п. ст.	1,250 п. физ. 62,5 п. юр. 0,625 п. ст.
Выручка с НДС, тыс. руб.	–	–	6 812,5	8 562,5	15 375
Сумма НДС, тыс. руб.	–	–	1 362,5	1 712,5	3 075

Продолжение таблицы 18

Показатели	Кварталы				Всего
	I	II	III	IV	
Нетто-выручка (без НДС), тыс. руб.	–	–	5 450	6 850	12 300

Таблица 19 – План продаж, год 2

Показатели	Кварталы				Всего
	I	II	III	IV	
Ожидаемый объем продаж, ед.	1300 п. физ. 55 п. юр. 1500 п. ст.	1400 п. физ. 60 п. юр. 1100 п. ст.	1500 п. физ. 50 п. юр. 600 п. ст.	1200 п. физ. 55 п. юр. 400 п. ст.	5400 п. физ. 220 п. юр. 3600 п. ст.
Цена с НДС, тыс. руб.	1,250 п. физ. 62,5 п. юр. 0,625 п. ст.	1,250 п. физ. 62,5 п. юр. 0,625 п. ст.	1,250 п. физ. 62,5 п. юр. 0,625 п. ст.	1,250 п. физ. 62,5 п. юр. 0,625 п. ст.	1,250 п. физ. 62,5 п. юр. 0,625 п. ст.
Выручка с НДС, тыс. руб.	6 000	6 187,5	5 375	5 187,5	22 750
Сумма НДС, тыс. руб.	1 200	1 237,5	1 075	1 037,5	4 550
Нетто-выручка (без НДС), тыс. руб.	4 800	4 950	4 300	4 150	18 200

Таблица 20 – План продаж, год 3

Показатели	Кварталы				Всего
	I	II	III	IV	
Ожидаемый объем продаж, ед.	1400 п. физ. 60 п. юр. 1400 п. ст.	1300 п. физ. 65 п. юр. 1200 п. ст.	1400 п. физ. 55 п. юр. 500 п. ст.	1200 п. физ. 60 п. юр. 500 п. ст.	5300 п. физ. 240 п. юр. 3600 п. ст.
Цена с НДС, тыс. руб.	1,250 п. физ. 62,5 п. юр. 0,625 п. ст.	1,250 п. физ. 62,5 п. юр. 0,625 п. ст.	1,250 п. физ. 62,5 п. юр. 0,625 п. ст.	1,250 п. физ. 62,5 п. юр. 0,625 п. ст.	1,250 п. физ. 62,5 п. юр. 0,625 п. ст.
Выручка с НДС, тыс. руб.	6 375	6 437,5	5 500	5 562,5	23 875

Продолжение таблицы 20

Показатели	Кварталы				Всего
	I	II	III	IV	
Сумма НДС, тыс. руб.	1 275	1 287,5	1 100	1 112,5	4 775
Нетто- выручка (без НДС), тыс. руб.	5 100	5 150	4 400	4 450	19 100

4.6 План производства

4.6.1 Производственная база

Деятельность будет осуществляться на вновь создаваемом предприятии. Планируется аренда офисного помещения. Для размещения 6 сотрудников, планируется арендовать помещение площадью 60 кв.м. Исходя из стоимости аренды, был выбран офис в Кировском районе г. Санкт-Петербурга по адресу Промышленная ул., 14а с арендной платой 46 880 руб. в месяц. Ремонт офисного помещения не планируется, так как оно находится в удовлетворительном состоянии.

Потребность в офисной мебели представлена в таблице 21.

Таблица 21 – Потребность в офисной мебели

№	Наименование	Стоимость с НДС, руб.	Количество	Сумма с НДС, руб.
1	Стол рабочий «Матрица» венге	2 554	6	15 324
2	Кресло офисное Бюрократ Т-898/3С1GR серое	5 099	6	30 594
3	Шкаф архивный ПАКС-металл ШАМ-11	9 559	2	19 118
4	Доска комбинированная магнитно-маркерно-меловая BRAUBERG Premium	11 521	1	11 521
Всего				76 557

Потребность в производственном оборудовании представлена в таблице 22.

Таблица 22 – Потребность в производственном оборудовании

№	Наименование	Стоимость с НДС, руб.	Количество	Сумма с НДС, руб.
1	Системный блок Atlas H286	36 999	6	221 994
2	Монитор Samsung S24F354FHI	8 899	8	71 192
3	Компактная мышь беспроводная Microsoft Bluetooth Mobile 3600 черная	1 499	6	8 994
4	Клавиатура Microsoft Bluetooth	3 050	6	18 300
5	Веб-камера Canyon CNE-CWC1	1 250	6	7 500
6	Bluetooth гарнитура DEXP BT-212 черная	1 049	6	6 294
7	МФУ лазерное HP LaserJet Pro MFP M28a	9 999	1	9 999
Всего				344 273

4.6.2 Потребность в производственном персонале

Потребность в персонале представлена в таблице 23.

Таблица 23 – Потребность в производственном персонале

№	Специальность	Вид	Численность, чел.	Рабочих часов в неделю	Заработная плата в месяц, руб.	Заработная плата за квартал, руб.
1	Системный администратор	Управляющий	1	40	70 000	210 000
2	Фронтенд-Разработчик	Неуправляющий	1	40	80 000	240 000
3	Бэкенд-разработчик	Неуправляющий	1	40	110 000	330 000
4	Бухгалтер	Управляющий	1	40	50 000	150 000
5	HR-специалист	Управляющий	1	40	40 000	120 000
6	Специалист по работе с клиентами	Управляющий	1	40	50 000	150 000

4.6.3 Расчет общепроизводственных затрат

Расчет общепроизводственных затрат, исходя из затрат на коммунальные услуги 30 000 руб. плюс 6 000 руб. НДС, и заработной платы неуправляющего персонала 190 000 руб. составит 226 000 руб. Таким образом общепроизводственных затраты в месяц составляют 226 000 руб. в месяц или

678 000 руб. за квартал.

4.6.4 Расчет общехозяйственных, управленческих и коммерческих расходов

Амортизация оборудования (линейная), учитывая срок полезного использования компьютера и компьютерной периферии в 3 года (36 месяцев), стоимость оборудования 344 273 руб., будет составлять 2,8% в месяц, то есть 9 639,64 руб. в месяц (28 918,92 руб. за квартал), а в последний месяц с учетом остатка 2%, то есть 6 885,46 руб. (26 164,74 руб. за квартал).

Расчет общехозяйственных, управленческих и коммерческих расходов приведен в таблице 24, в скобках указана сумма за последний месяц с учетом амортизации.

Таблица 24 – Расчет общехозяйственных, управленческих и коммерческих расходов

№	Вид расходов	В месяц, руб.	За квартал, руб.
1	Амортизация оборудования	9 639,64 (6 885,46)	28 918,92 (26 164,74)
2	Заработная плата управляющего персонала	210 000	630 000
3	Отчисления на социальные нужды административно управленческого персонала 30%	63 000	189 000
4	Отчисления на социальные нужды административно неуправленческого персонала 30%	57 000	171 000
5	Аренды производственного помещения	46 880	140 640
6	Услуги связи	10 000	30 000
7	Канцелярские товары	3 000	9 000
8	Выплата по кредиту	180 123	540 369
Всего		579 642,64 (576 888,46)	1 738 927,92 (1 736 173,74)

Учитываются также коммерческие расходы по рекламе и продвижению в соответствии с таблицами 16 и 17.

4.6.5 Расчет инвестиционных расходов

Расчет инвестиционных расходов приведен в таблице 25.

Таблица 25 – Расчет инвестиционных расходов

№	Наименование сумма	Сумма, руб.
1	Закупка офисного оборудования	344 273
2	Закупка офисной мебели	76 557
3	Регистрация предприятия, подготовка производства	6 700
Всего		432 530

4.6.6 Расчет затрат на разработку продукта

Расчет затрат на разработку продукта приведен в таблице 26. Он произведен с учетом первых 2 кварталов разработки, до момента выпуска продукта на рынок.

Таблица 26 – Расчет затрат на разработку продукта

№	Наименование сумма	Сумма, руб.
1	Общепроизводственные затраты	1 159 285,28
2	Общехозяйственные и управленческие расходы	3 477 855,84
3	Потребность в офисной мебели	76 557
4	Потребность в оборудовании	344 273
5	Выплаты процентов по кредиту	119 904,66
Итого затраты на разработку продукта		5 101 318,78

4.7 Организационный план

4.7.1 Характеристика организации, реализующей проект

Организационно-правовая форма организации – индивидуальное-предпринимательство.

4.7.2 Нормативно-правовое регулирование

С точки зрения нормативно-правового регулирования никаких специальных разрешений на деятельность, осуществляемую предприятием не требуется.

4.7.3 Организационная структура

В деятельности организации будут участвовать отделы:

- 1) HR-служба,

- 2) отдел системного администрирования,
- 3) отдел разработки,
- 4) бухгалтерия.

4.7.4 Календарный план проекта

Продолжительность этапов проекта приведен в таблице 27.

Таблица 27 – Продолжительность этапов проекта

№	Наименование работы	Предыдущие работы	Продолжительность, дни
1	Закупка оборудования и мебели	–	7
2	Подбор производственного персонала	–	7
3	Разработка технического задания	–	7
4	Расчет нагрузок	3	7
5	Проектирование программного пакета	4	30
6	Реализация и тестирование	4, 5	120
7	Поддержка программного пакета	6	–

График проекта приведен в таблице 25.

Таблица 28 – График проекта

№	Наименование работы	Янв.	Фев.	Мар.	Апр.	Май	Июнь	Июль
1	Закупка оборудования и мебели	×						
2	Подбор производственного персонала	×						
3	Разработка технического задания	×						
4	Расчет нагрузок	×						
5	Проектирование программного пакета		×					
6	Реализация и тестирование			×	×	×	×	
7	Поддержка программного пакета							×

4.8 Финансовый план

Развитие проекта предполагается за счет заемных средств путем оформления кредита. Вариантом для получения инвестиций будет оформление кредита, например, в ПАО Банк «Московский кредитный банк». Сумма

кредита составляет 5 765 000 руб., исходя из первоначальных затрат на проект (единовременные затраты на оборудование и оплату разработки в первые 2 квартала).

Ставка по кредиту составит 7,8%, срок кредита – 36 месяцев, ежемесячный платеж равен 180 123 руб. При данных условиях привлечения денежных средств переплата по кредиту составит 719 428 рублей, выплаты за весь срок кредита составит 6 484 428 руб.

4.8.1 План прибылей и убытков

Предприятие будет работать с уплатой налога в размере 20% от прибыли. График проекта приведен в таблицах 29, 30 и 31.

Таблица 29 – План прибылей и убытков, год 1

Показатели	Кварталы				Всего
	I	II	III	IV	
Выручка-нетто (без учета НДС) от реализации	–	–	5 450	6 850	12 300
Постоянные общепроизводственные затраты	678	678	678	678	2 712
Постоянные общехозяйственные, управленческие и коммерческие затраты	1 739	1 739	1 739	2 024	7 241
Прибыль от продаж	–2 417	–2 417	3 033	4 148	2 347
Налог 20%	–	–	607	829	1 436
Чистая (нераспределенная) прибыль	–2 417	–2 417	2 426	3 318	910

Таблица 30 – План прибылей и убытков, год 2

Показатели	Кварталы				Всего
	I	II	III	IV	
Выручка-нетто (без учета НДС) от реализации	4 800	4 950	4 300	4 150	18 200
Постоянные общепроизводственные затраты	678	678	678	678	2 712
Постоянные общехозяйственные, управленческие и коммерческие затраты	1 759	1 739	1 739	1 739	6 976
Прибыль от продаж	2 363	2 533	1 883	1 733	8 512
Налог 20%	473	507	377	347	1 702

Продолжение таблицы 30

Показатели	Кварталы				Всего
	I	II	III	IV	
Чистая (нераспределенная) прибыль	1 890	2 026	1 506	1 386	6 810

Таблица 31 – План прибылей и убытков, год 3

Показатели	Кварталы				Всего
	I	II	III	IV	
Выручка-нетто (без учета НДС) от реализации	5 100	5 150	4 400	4 450	19 100
Постоянные общепроизводственные затраты	678	678	678	678	2 712
Постоянные общехозяйственные, управленческие и коммерческие затраты	1 759	1 739	1 739	1 736	6 973
Прибыль от продаж	2 663	2 733	1 983	2 036	9 415
Налог 20%	533	547	397	407	1 883
Чистая (нераспределенная) прибыль	2 130	2 186	1 586	1 629	7 532

4.8.2 Показатели эффективности инвестиций

Период окупаемости рассчитывается по формуле 7:

$$PP = M - \frac{\sum_{t=0}^M CF_t}{CF_{M+1}}, \quad PP = 3 - \frac{-2\,841}{3\,318} = 3,86 \text{ кварталов} = 0,965 \text{ года}, \quad (7)$$

где PP – период окупаемости;

M – продолжительность реализации проекта до начала расчетного периода, на котором сальдо приобретает положительный характер;

CF_t – денежный поток, за шаг расчетного периода;

$\sum_{t=0}^M CF_t$ – накопленное сальдо на шаге, предшествующем окупаемости;

CF_{M+1} – денежный поток шага расчетного периода в течение которого происходит окупаемость.

Для расчета NPV необходима ставка дисконтирования, вычисленная по формуле 8 (WACC):

$$R = r_s \cdot \frac{V_s}{V} + r_d \cdot \frac{V_d}{V} \cdot (1 - T), \quad R = 0 + 0,078 \cdot 1 \cdot (1 - 0,2) = 0,0624, \quad (8)$$

где R – стоимость капитала,

r_s – ставка по собственному капиталу,

V_s – величина собственного капитала,

V – общая сумма капитала,

r_d – ставка по заемному капиталу,

V_d – величина заемного капитала,

T – ставка налога на прибыль.

Показатели NPV рассчитывается по формуле 9:

$$NPV = \sum_{t=0}^n \frac{CF_t}{(1 + R)^t}, \quad (9)$$

где NPV – значение показателя NPV,

n – количество временных периодов.

Результаты расчета NPV для жизненного цикла проекта (3 года) приведены в формуле 10:

$$NPV = \frac{910}{(1 + 0,0624)^0} + \frac{6810}{(1 + 0,0624)^1} + \frac{7532}{(1 + 0,0624)^2} = 13993,22. \quad (10)$$

4.9 Оценка риска проекта

Реестр рисков приведен в таблице 32.

Таблица 32 – Реестр рисков

Рисковая ситуация	Вероятность возникновения	Влияние на проект	Возможные способы реагирования на риск (меры снижения риска)
Неверная оценка рынка сбыта продукции (потребность в данном продукте)	Маловероятно	Восполняемые потери	Изменение продукта с учетом потребностей рынка
Рост конкуренции на рынке сбыта (появление на рынке производителей аналогичных продуктов)	Вероятно	Восполняемые потери	Доработка продукта с учетом потребностей рынка, понижение цен на подписку
Экономические риски (резкие колебания курсов валют)	Вероятно	Восполняемые потери	Снижение себестоимости, за счет экономии используемых ресурсов, понижение заработной платы и замедление темпов разработки т.п.
Санкционные меры против РФ	Вероятно	Восполняемые потери	Переориентация на отечественный рынок

4.10 Результаты составления бизнес-плана по коммерциализации результатов научно-исследовательской работы магистра

По результатам раздела, посвященного составлению бизнес-плана по коммерциализации результатов научно-исследовательской работы магистра можно заключить, что отличительные особенности разработанных продуктов, позволяют проекту составить конкуренцию на рынке и обеспечивают коммерческий успех, чему также способствуют научная база работы и продуманное программное обеспечение.

ЗАКЛЮЧЕНИЕ

Исходя из анализа методов формализации политик безопасности, было принято решение продолжать движение в сторону создания инструментов разметки датасетов, и моделей глубокого обучения. Таким образом было проведено первичное планирование процесса выполнения выпускной квалификационной работы магистра.

В результате выполнения работы было спроектировано и реализовано требуемое программное средство для сбора датасета, ориентированного на политики безопасности, и позволяющего создавать, обучающие выборки, ориентированные на формирование онтологического представления политик безопасности.

В ходе выпускной квалификационной работы были успешно проделаны следующие шаги:

- проведение анализа предметной области;
- разработка методики сбора, очистки и разметки обучающей выборки;
- проектирование инструментария для построения обучающей выборки, обеспечивающей обучение классификатора с учетом онтологического представления предметной области;
- реализация инструментария для построения обучающей выборки, обеспечивающей обучение классификатора с учетом онтологического представления предметной области.

По результатам раздела, посвященного составлению бизнес-плана по коммерциализации результатов научно-исследовательской работы магистра было показано, что отличительные особенности разработанных продуктов, позволяют проекту составить конкуренцию на рынке и обеспечивают коммерческий успех.

Все задачи, поставленные в выпускной квалификационной работе, были успешно выполнены. Файлы исходных кодов программ приведены в при-

ложениях А и Б. Электронная версия данной пояснительной записки к выпускной квалификационной работе представлена в приложении В.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1 General Data Protection Regulation, GDPR homepage. URL: <https://gdpr.eu> (дата обращения 14.02.2021).

2 Zimmeck, S., Story, P., Smullen, D., Ravichander, A., Wang, Z., Reidenberg, J.R., Russell N.C., Sadeh, N.: MAPS: Scaling Privacy Compliance Analysis to a Million Apps. In: Proceedings on Privacy Enhancing Technologies, 66, 2019, https://ir.lawnet.fordham.edu/faculty_scholarship/1040.

3 Oltramari, A., Piraviperumal, D., Schaub, F., Wilson, S., Cherivirala, S., Norton, T., Russell, N., Story, P., Reidenberg, J., Sadeh, N.: PrivOnto: A semantic framework for the analysis of privacy policies. Semantic Web, 9(2), 2018; pp. 185-203.

4 Kumar V.B., Iyengar R., Nisal N., Feng Y., Habib H., Story P., Cherivirala S., Hagan M., Cranor L., Wilson C., Schaub F., and Sadeh N.: Finding a Choice in a Haystack: Automatic Extraction of Opt-Out Statements from Privacy Policy Text. In: Proceedings of The Web Conference 2020 (WWW '20), pp. 1943-1954. New York, NY, USA, Association for Computing Machinery, 2020.

5 Palmirani, M., Martoni, M., Rossi, A., Bartolini, C., Robaldo, L.: Legal ontology for modelling GDPR concepts and norms. Legal Knowledge and Information Systems. IOS Press, 2018. doi: <https://doi.org/10.3233/978-1-61499-935-5-5-91>.

6 Pandit, H. J., O'Sullivan D., Lewis D. An Ontology Design Pattern for Describing Personal Data in Privacy Policies. WOP@ISWC, 2018.

7 Sathyendra, K. M., Schaub, F., Wilson, S., Sadeh, N.: Automatic extraction of opt-out choices from privacy policies. In Proc. AAAI Symposium on Privacy-Enhancing Technologies, AAAI Fall Symposium - Technical Report, 2016.

8 Ashley, P., Hada, S., Karjoth, G., Schunter, M.: E-p3p privacy policies and privacy authorization. In: Proc. of the ACM work-shop on Privacy in the

Electronic Society (WPES 2002), Washington, DC, USA, 2002.

9 Karjoth, G., Schunter, M.: Privacy policy model for enterprises. In: Proc. of the 15th IEEE Computer Security Foundations Workshop, Cape Breton, Nova Scotia, Canada, 2002.

10 Ardagna, C.A., De Capitani di Vimercati, S., Samarati, P.: Enhancing User Privacy Through Data Handling Policies. In: Damiani E., Liu P. (eds) Data and Applications Security XX. DBSec 2006. Lecture Notes in Computer Science, vol. 4127. Springer, Berlin, Heidelberg, 2006.

11 Pardo, R., Le Métayer, D.: Analysis of Privacy Policies to Enhance Informed Consent. In: Foley S. (eds) Data and Applications Security and Privacy XXXIII. DBSec 2019. Lecture Notes in Computer Science, vol. 11559. Springer, Cham, 2019.

12 Gerl, A., Bennani, N., Kosch, H., Brunie, L.: LPL, Towards a GDPR-Compliant Privacy Language: Formal Definition and Usage. Trans. Large-Scale Data- and Knowledge-Centered Systems 2018, 37, pp. 41-80.

13 NIST Privacy Risk Assessment Methodology (PRAM). Available online: <https://www.nist.gov/itl/applied-cybersecurity/privacy-engineering/resources> (accessed on 30 March 2021).

14 De, S.J., Le Metayer, D.: Privacy Risk Analysis to Enable Informed Privacy Settings. In: 2018 IEEE European Symposium on Security and Privacy Workshops (EuroS&PW), London, pp. 95-102, 2018.

15 Evgenia Novikova, Elena Doynikova, and Igor Kotenko. P2Onto: Making Privacy Policies Transparent. Springer, 2020.

16 Children's Online Privacy Protection Rule ("COPPA"). Available online: <https://www.ftc.gov/enforcement/rules/rulemaking-regulatory-reform-proceedings/childrens-online-privacy-protection-rule> (accessed on 30 March 2021).

17 Health Information Privacy. Available online: <https://www.hhs.gov/hipaa/index.html> (accessed on 30 March 2021).

18 The Usable Privacy Policy Project. Available online: <https://usablepriv>

acy.org/ (accessed on 30 March 2021).

19 Novikova, E., Doynikova, E., Kotenko, I.: P2Onto: Making Privacy Policies Transparent. In Proceedings of The 3rd International Workshop on Attacks and Defenses for Internet-of-Things (ADIoT 2020), In Conjunction with ESORICS 2020. 4-6 November 2020, Paris, France. Computer Security, Lecture Notes in Computer Science (LNCS), Springer, 2020; vol. 12501; pp. 235-252. DOI: https://doi.org/10.1007/978-3-030-64330-0_15

20 PROV_O: The PROV Ontology Homepage. Available online: <https://www.w3.org/TR/prov-o/#Agent> (accessed on 30 March 2021).

21 Landauer, T. K., Foltz, P. W., and Laham, D. An Introduction to Latent Semantic Analysis. *Discourse Processes*, 25, 1998, pp. 259-284. DOI: <https://doi.org/10.1080/01638539809545028>.

22 Gensim topic modeling library, Gensim homepage. URL: <https://radimrehurek.com/gensim> (дата обращения 14.02.2021).

23 Hamza Harkous, Kassem Fawaz, Remi Lebret, Florian Schaub³, Kang G. Shin, and Karl Aberer. Polisis: Automated Analysis and Presentation of Privacy Policies Using Deep Learning. 2018. arXiv:1802.02561v2.

24 Sachini Weerawardhana, Subhojeet Mukherjee, Indrajit Ray, and Adele Howe. Automated Extraction of Vulnerability Information for Home Computer Security, pages 356-366. Springer, 2015. DOI: https://doi.org/10.1007/978-3-319-17040-4_24.

25 Natural Language ToolKit, Analyzing Sentence Structure, NLTK homepage. URL: <https://www.nltk.org/book/ch08.html> (дата обращения 14.02.2021).

ПРИЛОЖЕНИЕ А

Архив с исходными кодами вэб-скрейпера.

ПРИЛОЖЕНИЕ Б

Архив с исходными кодами инструмента для разметки дата сета.

ПРИЛОЖЕНИЕ В

Электронная версия пояснительной записки.